

# L1凸松弛压缩感知信号恢复

## 1 摘要

压缩感知理论指出，当信号具有稀疏性或可压缩性时，可以通过远低于奈奎斯特率的线性测量以高概率恢复原始信号。最直接的 L0 稀疏恢复问题是 NP-难的组合优化问题，本文引入 L1 凸松弛将其转化为凸优化问题，并围绕带噪声稀疏信号恢复展开研究。

本文不调用任何商用凸优化求解器，自主实现了 FISTA 加速近端梯度算法；针对约束形式 L1 恢复问题，设计了  $\lambda$  几何递减序列与残差曲线插值策略，稳健匹配残差约束  $\delta$ ；同时采用解析伪逆作为 L2 最小范数基线，保证对比公平并降低计算开销。

在仿真实验中，本文系统分析了采样维度  $M$ 、稀疏度  $K$  与噪声强度  $\sigma$  对重建性能的影响。结果表明：观测维度存在明显的相变临界值，当  $M$  超过临界值时支撑集恢复成功率快速趋近 100%；噪声会抬升临界采样规模并降低重建精度；L1 凸松弛恢复效果显著优于 L2 最小范数基线。

**关键词：**压缩感知；L1 凸松弛；FISTA；稀疏恢复；相变现象；KKT 条件

## 2 引言

奈奎斯特采样定理指出，要无失真地重建带限信号，采样率不得低于信号最高频率的两倍。然而在许多实际场景中，信号本身具有稀疏性或可压缩性，传统均匀采样方式获取了大量冗余数据，采样与存储成本高昂。压缩感知理论表明，对于稀疏信号，可以通过远低于奈奎斯特率的线性测量以高概率精确恢复，其核心在于利用信号的稀疏结构<sup>[1]</sup>。

考虑  $K$ -稀疏信号  $x \in \mathbb{R}^n$ （即至多  $K$  个非零分量），通过测量矩阵  $A \in \mathbb{R}^{M \times n}$ （ $M < n$ ）得到观测  $y = Ax$ 。理论上最直接的恢复模型是 L0 范数极小化

$$\min_{x \in \mathbb{R}^n} \|x\|_0 \quad \text{s.t.} \quad Ax = y,$$

但该问题是 NP-难的组合优化问题，难以大规模精确求解。L1 凸松弛将 L0 范数替换为 L1 范数，得到凸优化问题，从而能够高效求解，并在一定条件下保证恢复精度<sup>[2]</sup>。

在现有课程作业或朴素实现中，常见以下几类简化缺陷：

- 直接对正则参数  $\lambda$  二分搜索，忽略残差函数  $r(\lambda)$  单调非减但非严格单调、以及离散路径数值误差带来的失效风险；
- L2 基线采用迭代梯度投影，收敛缓慢且引入额外数值误差；
- 使用固定阈值  $|x_i| > \tau$  判定支撑集，噪声环境下易漏判、误判；
- 使用未加速的 ISTA，收敛速度慢，批量仿真耗时高。

本项目针对上述问题，设计并实现稳健的约束 L1 恢复方案：自研 FISTA 求解 LASSO，采用  $\lambda$  几何序列与插值策略匹配残差约束，使用解析伪逆作为 L2 对照基线，并采用 Top-K 集合相等判定支撑集恢复成功率。

本项目的研究目标分为四层：

1. **理论**: 推导约束优化模型的 KKT 条件, 理解 L1 凸松弛的可行性与最优性;
2. **算法**: 自研 FISTA 求解 LASSO, 并设计稳健的  $\lambda$  寻根策略实现约束形式 L1 恢复;
3. **实验**: 定量分析观测维度  $M$ 、稀疏度  $K$ 、噪声强度  $\sigma$  对重建性能的影响, 观测相变现象;
4. **对比**: 与解析 L2 最小范数基线进行对照, 结合 RIP 理论分析仿真结果。

### 3 问题建模与凸优化理论基础

本章研究带噪声稀疏信号恢复问题, 依次建立信号观测模型、L0 稀疏恢复的 L1 凸松弛模型, 推导其 KKT 条件, 并给出对偶问题与强对偶性结论。

#### 3.1 信号观测模型

研究问题为带噪声稀疏信号恢复。设原始信号  $x_{\text{true}} \in \mathbb{R}^n$  是  $K$ -稀疏信号 (即至多  $K$  个非零分量), 通过高斯随机测量矩阵  $A \in \mathbb{R}^{M \times n}$  得到观测向量  $y \in \mathbb{R}^M$ , 观测过程受到高斯噪声  $e \sim \mathcal{N}(0, \sigma^2 I_M)$  污染:

$$y = Ax_{\text{true}} + e, \quad e \sim \mathcal{N}(0, \sigma^2 I_M). \quad (1)$$

各符号含义见表 1。

| 符号                                 | 含义                                            |
|------------------------------------|-----------------------------------------------|
| $x_{\text{true}} \in \mathbb{R}^n$ | $K$ -稀疏原始信号                                   |
| $A \in \mathbb{R}^{M \times n}$    | 高斯随机测量矩阵, $M < n$                             |
| $e \in \mathbb{R}^M$               | 高斯观测噪声, $e \sim \mathcal{N}(0, \sigma^2 I_M)$ |
| $y \in \mathbb{R}^M$               | 观测向量                                          |
| $K$                                | 原始信号稀疏度                                       |
| $M$                                | 观测维度                                          |

表 1: 符号说明

#### 3.2 L0 稀疏恢复与 L1 凸松弛

**无噪声 L0 恢复模型** 在无噪声情形下, 稀疏恢复问题可写为如下 L0 范数极小化问题:

$$\min_{x \in \mathbb{R}^n} \|x\|_0 \quad \text{s.t.} \quad Ax = y, \quad (2)$$

其中  $\|x\|_0$  表示向量  $x$  中非零分量的个数。

**带噪声约束 L0 恢复模型** 现实观测必然含有噪声, 等式约束  $Ax = y$  无法严格满足, 因此将其替换为残差约束  $\|Ax - y\|_2 \leq \delta$ , 得到带噪声约束的 L0 模型:

$$\min_{x \in \mathbb{R}^n} \|x\|_0 \quad \text{s.t.} \quad \|Ax - y\|_2 \leq \delta. \quad (3)$$

然而, L0 范数非凸、不连续, 对应的组合优化问题难以大规模精确求解, 因此考虑将 L0 范数凸松弛为 L1 范数。

**L1 凸松弛问题** 将 (3) 中的  $\|x\|_0$  替换为  $\|x\|_1$ , 得到核心优化问题

$$(P) \quad \min_{x \in \mathbb{R}^n} \|x\|_1 \quad \text{s.t.} \quad \|Ax - y\|_2 \leq \delta. \quad (4)$$

**凸性论证** 问题 (4) 中, 目标函数  $\|x\|_1$  是凸函数; 约束函数  $\|Ax - y\|_2$  是凸函数, 因此可行域

$$\{x \in \mathbb{R}^n : \|Ax - y\|_2 \leq \delta\}$$

是凸集。于是问题 (4) 是一个凸优化问题, 其局部最优解等价于全局最优解<sup>[3]</sup>。

**噪声阈值  $\delta$  的选取** 对于观测模型 (1), 残差向量

$$r = Ax - y = A(x - x_{\text{true}}) - e.$$

当  $x = x_{\text{true}}$  时, 真实残差满足

$$r_{\text{true}} = -e \sim \mathcal{N}(0, \sigma^2 I_M).$$

标准化得  $\frac{1}{\sigma} r_{\text{true}} \sim \mathcal{N}(0, I_M)$ , 于是

$$Z = \frac{1}{\sigma^2} \|r_{\text{true}}\|_2^2 = \frac{1}{\sigma^2} \|e\|_2^2 \sim \chi^2(M). \quad (5)$$

由卡方分布的高概率上界, 可取

$$\delta = \sigma \sqrt{M + 2\sqrt{2M}}. \quad (6)$$

$\delta$  的取值影响可行域大小: 取得过小可能导致可行域为空, 取得过大会使约束过于松弛, 解过度稀疏、失真严重。

### 3.3 KKT 条件推导

对于凸优化问题 (4), 构造拉格朗日函数

$$L(x, \lambda) = \|x\|_1 + \lambda(\|Ax - y\|_2 - \delta), \quad \lambda \geq 0. \quad (7)$$

由于  $\|x\|_1$  在原点不可微, 稳定性条件中的梯度应替换为次梯度。 $\|x\|_1$  的次微分为

$$\partial\|x\|_1 = \{s \in \mathbb{R}^n : s_i \in \partial|x_i|, i = 1, \dots, n\}, \quad (8)$$

其中

$$\partial|x_i| = \begin{cases} \{1\}, & x_i > 0, \\ \{-1\}, & x_i < 0, \\ [-1, 1], & x_i = 0. \end{cases} \quad (9)$$

当  $\|Ax - y\|_2 \neq 0$  时,  $\|Ax - y\|_2$  可微, 其次梯度即梯度

$$\partial_x \|Ax - y\|_2 = \frac{A^T(Ax - y)}{\|Ax - y\|_2}. \quad (10)$$

因此, 若  $x^*$  是问题 (4) 的最优解, 则存在乘子  $\lambda^* \geq 0$ , 使得如下 KKT 条件成立:

1. 稳定性条件 (次梯度最优性):

$$-\lambda^* \frac{A^T(Ax^* - y)}{\|Ax^* - y\|_2} \in \partial\|x^*\|_1. \quad (11)$$

2. 原问题可行:

$$\|Ax^* - y\|_2 \leq \delta.$$

3. 对偶可行:

$$\lambda^* \geq 0.$$

## 4. 互补松弛:

$$\lambda^*(\|Ax^* - y\|_2 - \delta) = 0. \quad (12)$$

互补松弛条件说明：若  $\lambda^* > 0$ ，则必有  $\|Ax^* - y\|_2 = \delta$ ，即最优解位于约束边界上，约束被激活；若  $\lambda^* = 0$ ，则约束不起作用，问题退化为无约束极小化  $\|x\|_1$ 。在 Slater 条件成立时（见第 3.4 节），上述 KKT 条件也是全局最优的充分条件。

## 3.4 对偶问题与强对偶性

**对偶函数推导** 由拉格朗日函数 (7)，定义对偶函数

$$g(\lambda) = \inf_{x \in \mathbb{R}^n} L(x, \lambda) = -\lambda\delta + \inf_{x \in \mathbb{R}^n} (\|x\|_1 + \lambda\|Ax - y\|_2), \quad \lambda \geq 0. \quad (13)$$

利用范数的共轭表示  $\|z\|_2 = \sup_{\|u\|_2 \leq 1} u^T z$ ，并交换  $\inf$  与  $\sup$ （由 Slater 条件保证其合理性），可得

$$\inf_{x \in \mathbb{R}^n} (\|x\|_1 + \lambda\|Ax - y\|_2) = \sup_{\|u\|_2 \leq 1} \left( -\lambda u^T y + \inf_{x \in \mathbb{R}^n} (\|x\|_1 + \lambda(A^T u)^T x) \right). \quad (14)$$

由于

$$\inf_{x \in \mathbb{R}^n} (\|x\|_1 + z^T x) = \begin{cases} 0, & \|z\|_\infty \leq 1, \\ -\infty, & \text{否则}, \end{cases}$$

令  $v = \lambda u$ ，则

$$g(\lambda) = -\lambda\delta + \sup_{\|v\|_2 \leq \lambda, \|A^T v\|_\infty \leq 1} (-v^T y). \quad (15)$$

于是拉格朗日对偶问题为

$$\max_{\lambda \geq 0} g(\lambda) = \max_{\lambda \geq 0, \|v\|_2 \leq \lambda, \|A^T v\|_\infty \leq 1} (-\delta\lambda - v^T y). \quad (16)$$

对固定的  $v$ ，由于  $\delta > 0$ ，最优的  $\lambda$  取  $\lambda = \|v\|_2$ ，故 (16) 等价于

$$\min_{v \in \mathbb{R}^M} y^T v + \delta\|v\|_2 \quad \text{s.t.} \quad \|A^T v\|_\infty \leq 1. \quad (17)$$

记 (17) 的最优值为  $q^*$ ，拉格朗日对偶问题 (16) 的最优值为  $d^*$ ，则有  $d^* = -q^*$ ；强对偶成立时，原问题最优值  $p^*$  满足  $p^* = d^* = -q^*$ 。

**Slater 条件验证** 约束函数  $\|Ax - y\|_2$  是凸函数。当  $\delta > 0$  且  $A$  行满秩时（高斯随机矩阵以概率 1 行满秩），方程  $Ax = y$  有解，因此存在严格可行点  $x$  满足  $\|Ax - y\|_2 = 0 < \delta$ ，Slater 条件成立。当  $\delta = 0$ （即无噪声情形）时，可行域退化为仿射集  $\{x : Ax = y\}$ ，强对偶性仍可由线性约束凸优化理论保证，也可视为  $\delta \downarrow 0$  的极限情形。

**强对偶结论** 综上，问题 (4) 满足约束规格，强对偶成立，原问题与对偶问题之间存在确定的最优值对应关系；这一性质为后续设计自研求解器与验证最优性提供了理论基础。

## 4 自研求解器：加速近端梯度算法（FISTA）

本章针对约束问题 (4)，给出其等价 LASSO 形式与  $\lambda$  寻根策略，推导近端算子与软阈值公式，并建立 ISTA/FISTA 迭代算法及收敛性分析。

### 4.1 约束问题等价转化与 $\lambda$ 寻根策略

原约束问题 (4) 可等价地表述为：存在参数  $\lambda > 0$ ，使得 LASSO 问题

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - y\|_2^2 + \lambda \|x\|_1 \quad (18)$$

的最优解  $x_\lambda$  同时满足残差约束

$$\|Ax_\lambda - y\|_2 = \delta.$$

残差函数  $r(\lambda) = \|Ax_\lambda - y\|_2$  关于  $\lambda$  单调非减，但可能存在非严格单调区间；在有限迭代和离散  $\lambda$ -path 下，直接求解精确  $\lambda$  还存在数值误差，因此采用几何路径 + 插值策略：构造  $\lambda$  的几何递减序列，上限取  $\|A^T y\|_\infty$ ，下限取  $10^{-6} \|A^T y\|_\infty$ ；对每个  $\lambda$  求解 LASSO (18)，得到残差曲线  $r(\lambda)$ ，再利用插值方法寻找满足  $r(\lambda) = \delta$  的目标  $\lambda$ 。

### 4.2 近端算子理论推导

对于闭凸函数  $f: \mathbb{R}^n \rightarrow (-\infty, +\infty]$ ，给定参数  $\tau > 0$ ，近端算子定义为

$$\text{prox}_{\tau f}(v) = \arg \min_{x \in \mathbb{R}^n} \left\{ f(x) + \frac{1}{2\tau} \|x - v\|_2^2 \right\}. \quad (19)$$

其含义是在尽量保持  $x$  接近  $v$  的同时使  $f(x)$  尽量小。

对 LASSO 问题 (18)，令

$$g(x) = \frac{1}{2} \|Ax - y\|_2^2, \quad h(x) = \lambda \|x\|_1,$$

则目标函数为  $g(x) + h(x)$ ，其中  $g$  可微、 $h$  不可微但凸。采用“梯度下降处理  $g$ 、近端算子处理  $h$ ”的策略。

考虑  $h(x) = \lambda \|x\|_1$ ，由定义 (19) 得

$$\text{prox}_{\tau h}(v) = \arg \min_{x \in \mathbb{R}^n} \left\{ \tau \lambda \|x\|_1 + \frac{1}{2} \|x - v\|_2^2 \right\}. \quad (20)$$

将目标函数写开：

$$\frac{1}{2} \|x - v\|_2^2 + \tau \lambda \|x\|_1 = \sum_{i=1}^n \left[ \frac{1}{2} (x_i - v_i)^2 + \tau \lambda |x_i| \right].$$

因此  $n$  维问题可分解为  $n$  个独立的一维问题。对标量问题

$$\min_{u \in \mathbb{R}} \phi(u) = \frac{1}{2} (u - v)^2 + \alpha |u|,$$

其中记  $\alpha = \tau \lambda$ 。由于  $|u|$  在 0 处不可微，分情况讨论：

- 若  $u > 0$ ，则  $\phi(u) = \frac{1}{2} (u - v)^2 + \alpha u$ ，令  $\phi'(u) = u - v + \alpha = 0$ ，得  $u^* = v - \alpha$ ，需满足  $v > \alpha$ ；
- 若  $u < 0$ ，则  $\phi(u) = \frac{1}{2} (u - v)^2 - \alpha u$ ，令  $\phi'(u) = u - v - \alpha = 0$ ，得  $u^* = v + \alpha$ ，需满足  $v < -\alpha$ ；
- 若  $u = 0$ ，由次梯度  $\partial|u|_{u=0} = [-1, 1]$ ，最优性条件  $0 \in \partial\phi(0) = -v + \alpha[-1, 1]$ ，即  $-\alpha \leq v \leq \alpha$ 。

综合得分段解

$$u^* = \begin{cases} v - \alpha, & v > \alpha, \\ 0, & |v| \leq \alpha, \\ v + \alpha, & v < -\alpha. \end{cases} \quad (21)$$

回代  $\alpha = \tau \lambda$  并写成符号函数形式，即得软阈值算子

$$S_{\tau \lambda}(v) = \text{sign}(v) \max\{|v| - \tau \lambda, 0\}. \quad (22)$$

对向量逐元素作用，有

$$\text{prox}_{\tau \lambda \|\cdot\|_1}(v) = (S_{\tau \lambda}(v_1), \dots, S_{\tau \lambda}(v_n))^T. \quad (23)$$

### 4.3 ISTA 与 FISTA 迭代算法

**近端梯度迭代格式** 对光滑部分  $g$  在  $x_k$  处作一阶近似，并加上邻近项以保证数值稳定性：

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ g(x_k) + \nabla g(x_k)^T (x - x_k) + \frac{1}{2t} \|x - x_k\|_2^2 + h(x) \right\}, \quad (24)$$

其中  $t > 0$  为步长。配方并略去与  $x$  无关的常数项，可得

$$x_{k+1} = \text{prox}_{th}(x_k - t\nabla g(x_k)).$$

对于  $h(x) = \lambda\|x\|_1$ ，有  $\text{prox}_{th}(v) = S_{t\lambda}(v)$ ，且  $\nabla g(x) = A^T(Ax - y)$ ，因此 ISTA 迭代格式为

$$x_{k+1} = S_{t\lambda}(x_k - tA^T(Ax_k - y)). \quad (25)$$

步长取  $0 < t \leq 1/L$ ，其中  $L = \|A\|_2^2$  是  $\nabla g$  的 Lipschitz 常数，见下文收敛性分析。

**FISTA 加速** ISTA 每一步只利用当前点  $x_k$  的信息，收敛速度较慢。FISTA 引入 Nesterov 外推点  $y_k$  加速：

$$x_{k+1} = \text{prox}_{th}(y_k - t\nabla g(y_k)). \quad (26)$$

辅助序列  $t_k$  与外推点更新为

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad (27)$$

$$y_{k+1} = x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k). \quad (28)$$

通常取初值  $t_1 = 1$ 、 $y_1 = x_0$ 。FISTA 在目标函数值意义下具有  $O(1/k^2)$  的收敛率<sup>[4]</sup>，相比 ISTA 的  $O(1/k)$ （见后文 ISTA 收敛性）有本质加速。

**步长选取**  $g$  的梯度 Lipschitz 常数为

$$\|\nabla g(x) - \nabla g(z)\|_2 = \|A^T A(x - z)\|_2 \leq \|A^T A\|_2 \|x - z\|_2,$$

故  $L = \|A^T A\|_2 = \|A\|_2^2$ 。步长可取  $t = 1/L = 1/\|A\|_2^2$ ，其中  $\|A\|_2^2$  通过计算  $A^T A$  的最大特征值得到。

**ISTA 收敛性** 设  $x^*$  为问题 (18) 的最优解， $F(x) = g(x) + h(x)$ 。由  $g$  的 Lipschitz 梯度性质，当  $t \leq 1/L$  时，

$$g(x) \leq g(z) + \nabla g(z)^T (x - z) + \frac{1}{2t} \|x - z\|_2^2. \quad (29)$$

定义代理函数

$$Q_t(x, z) = g(z) + \nabla g(z)^T (x - z) + \frac{1}{2t} \|x - z\|_2^2 + h(x), \quad (30)$$

则  $F(x) \leq Q_t(x, z)$ ，且 ISTA 更新 (25) 等价于  $x_{k+1} = \arg \min_x Q_t(x, x_k)$ 。由最优性条件，存在  $s_{k+1} \in \partial h(x_{k+1})$  使得

$$\nabla g(x_k) + \frac{1}{t}(x_{k+1} - x_k) + s_{k+1} = 0.$$

由  $h$  的凸性可得

$$h(x_{k+1}) - h(x) \leq -\nabla g(x_k)^T (x_{k+1} - x) - \frac{1}{t}(x_{k+1} - x_k)^T (x_{k+1} - x),$$

由  $g$  的凸性与 (29) 可得

$$g(x_{k+1}) - g(x) \leq \nabla g(x_k)^T (x_{k+1} - x) + \frac{1}{2t} \|x_{k+1} - x_k\|_2^2.$$

两式相加并利用恒等式

$$2(a-b)^T(a-c) = \|a-b\|_2^2 + \|a-c\|_2^2 - \|b-c\|_2^2$$

整理得

$$F(x_{k+1}) - F(x) \leq \frac{1}{2t} (\|x_k - x\|_2^2 - \|x_{k+1} - x\|_2^2). \quad (31)$$

令  $x = x^*$  并对  $k = 0, \dots, N-1$  求和, 利用 Telescoping 求和得

$$\sum_{k=0}^{N-1} (F(x_{k+1}) - F^*) \leq \frac{1}{2t} \|x_0 - x^*\|_2^2.$$

又因  $F(x_k)$  单调不增, 故

$$F(x_N) - F^* \leq \frac{1}{N} \sum_{k=0}^{N-1} (F(x_{k+1}) - F^*) \leq \frac{\|x_0 - x^*\|_2^2}{2tN}.$$

因此

$$F(x_N) - F^* = O\left(\frac{1}{N}\right), \quad (32)$$

即 ISTA 具有  $O(1/k)$  收敛率。

**停机准则** 采用双重停机准则:

- 相对迭代变化:

$$r_x^{(k)} = \frac{\|x_{k+1} - x_k\|_2}{\max(1, \|x_k\|_2)} < 10^{-5};$$

- 相对目标函数变化:

$$r_F^{(k)} = \frac{|F_{k+1} - F_k|}{\max(1, |F_k|)} < 10^{-8};$$

- 当迭代次数达到  $k_{\max} = 500$  时强制停机。

前两项同时满足时认为算法收敛; 若达到最大迭代次数仍未满足, 则强制终止并保留当前迭代解。

#### 4.4 L2 基线求解方案

为了公平对比 L1 凸松弛方法的效果, 本节实现一个 L2 最小范数基线求解器。其对比优化模型为

$$\min_{x \in \mathbb{R}^n} \|x\|_2 \quad \text{s.t.} \quad \|Ax - y\|_2 \leq \delta. \quad (33)$$

该模型不利用稀疏性, 仅寻找能量最小的可行解, 作为实验中的朴素对照。

**解析伪逆闭式解** 需要说明的是, 问题 (33) 的最优解通常位于可行域边界  $\|Ax - y\|_2 = \delta$  上, 并不等于等式约束  $Ax = y$  下的最小范数解。但在欠定情形  $M < n$  且  $A$  行满秩时,  $Ax = y$  有解, 此时可取等式约束最小范数解

$$\hat{x}_{L2} = A^T(AA^T)^{-1}y \quad (34)$$

作为 L2 基线的简化实现。该解残差为零, 恒满足  $\|A\hat{x}_{L2} - y\|_2 \leq \delta$ , 因而是 (33) 的一个可行解; 虽然它不一定是最优解, 但不利用稀疏性、计算简单、对比公平, 足以作为朴素对照。相比原始方案中的梯度投影迭代, 解析伪逆具有以下优点:

- 闭式求解, 计算开销低;
- 不引入迭代收敛误差, 保证对比公平;
- 在欠定行满秩情形下, 伪逆解恒满足残差约束  $\|A\hat{x}_{L2} - y\|_2 \leq \delta$ 。

**可行性讨论** 当  $A$  行满秩时,  $Ax = y$  有解, 因此  $\hat{x}_{L2}$  的残差为零, 对任意  $\delta \geq 0$  均可行。若因数值或退化情形导致残差超过  $\delta$ , 理论上可启用投影策略, 但本实验场景直接使用解析解, 以保证 L2 基线的实现简单且公平。

## 5 仿真实验方案设计

本章规定批量仿真实验的完整方案, 包括参数网格、噪声阈值、评价指标、单次实验流程与数据保存方式, 为后续实验运行和结果分析提供统一标准。

### 5.1 实验参数汇总

固定参数: 信号长度  $n = 128$ 。变量网格如表 2 所示。

| 参数             | 取值                                  |
|----------------|-------------------------------------|
| 观测维度 $M$       | 20, 30, 40, 50, 60, 70, 80, 90, 100 |
| 稀疏度 $K$        | 3, 5, 8, 12, 16, 20                 |
| 噪声标准差 $\sigma$ | 0, 0.02, 0.05, 0.10                 |
| 每组随机试验次数       | 50                                  |

表 2: 实验参数网格

每组参数  $(M, K, \sigma)$  独立重复 50 次随机试验。

### 5.2 噪声阈值 $\delta$ 选取规则

由第 3.1 节的分析, 取

$$\delta = \sigma \sqrt{M + 2\sqrt{2M}}. \quad (35)$$

该阈值来自卡方分布  $\chi^2(M)$  的高概率上界, 使真实残差以较高概率满足约束。 $\delta$  的取值影响可行域大小: 取得过小可能导致可行域为空; 取得过大会使约束过于松弛, 解过度稀疏、失真严重。特别地, 当  $\sigma = 0$  时  $\delta = 0$ , 对应无噪声情形下的精确约束  $Ax = y$ 。

### 5.3 评价指标定义

**支撑集恢复成功率** 已知真实稀疏度  $K$ 。对重建向量  $\hat{x}$ , 取绝对值最大的前  $K$  个坐标构成估计支撑集

$$\hat{S} = \arg \max_{|S|=K} \sum_{i \in S} |\hat{x}_i|, \quad (36)$$

即若

$$|\hat{x}_{i_1}| \geq |\hat{x}_{i_2}| \geq \dots \geq |\hat{x}_{i_K}| \geq \max_{j \notin \hat{S}} |\hat{x}_j|,$$

则

$$\hat{S} = \{i_1, i_2, \dots, i_K\}.$$

将估计支撑集  $\hat{S}$  与真实支撑集  $S_{\text{true}}$  做集合相等判定, 单次试验成功当且仅当  $\hat{S} = S_{\text{true}}$ 。禁止使用固定阈值  $|\hat{x}_i| > \tau$  判定支撑集, 因为噪声环境下固定阈值会产生漏判和误判。

**相对重建误差** 相对重建误差定义为

$$RE = \frac{\|\hat{x} - x_{\text{true}}\|_2}{\|x_{\text{true}}\|_2}. \quad (37)$$

$RE$  仅作为连续量化指标, 不作为支撑集成功判定标准。



### 5.4 单次完整实验流程

对每一组参数  $(M, K, \sigma)$  和每一次随机试验，按以下步骤执行：

1. 生成  $K$ -稀疏原始信号  $x_{\text{true}} \in \mathbb{R}^n$ ：随机选取  $K$  个支撑位置，非零分量独立服从标准正态分布；
2. 生成高斯随机测量矩阵  $A \in \mathbb{R}^{M \times n}$ ，元素独立服从标准正态分布；
3. 生成高斯噪声  $e \sim \mathcal{N}(0, \sigma^2 I_M)$ ，构造观测向量

$$y = Ax_{\text{true}} + e;$$

4. 按 (35) 计算  $\delta$ ，使用第 4.1 节的 FISTA+LASSO 路径插值方法求解约束 L1 恢复问题 (4)，得到  $\hat{x}_{L1}$ ；
5. 使用第 4.4 节的解析伪逆最小范数解作为 L2 基线（等式约束近似）

$$\hat{x}_{L2} = A^T(AA^T)^{-1}y;$$

6. 分别计算  $\hat{x}_{L1}$ 、 $\hat{x}_{L2}$  的支撑集恢复结果与相对重建误差 (37)；
7. 重复上述过程 50 次，统计支撑集恢复成功率与平均相对重建误差。

### 5.5 统计量与数据保存

对每组参数  $(M, K, \sigma)$ ，统计以下指标：

- 支撑集恢复成功率：50 次试验中  $\hat{S} = S_{\text{true}}$  的次数占比；
- 平均相对重建误差：50 次试验的  $RE$  均值，L1 与 L2 分别统计。

将最终统计结果保存为 `.npy` 文件，避免重复运算。



### 5.6 代码实现模块



实验代码按以下模块组织：

- `FISTA.py`：自研 FISTA 求解 LASSO；
- `lasso.py`：基于 FISTA 的  $\lambda$  几何序列与插值寻根，求解约束 L1 问题；
- `l2.baseline.py`：L2 基线解析伪逆求解；
- `experiment.py`：参数网格三层循环、50 次随机试验、指标统计与结果保存。

## 6 实验结果可视化

本章展示四类实验结果图表：无噪声相变热力图、支撑恢复成功率随观测维度变化折线图、L1 与 L2 平均相对重建误差对比图，以及单次样例恢复对照图。

图 6-1: 无噪声情形 ( $\sigma = 0$ ) 下 L1 支撑集恢复成功率热力图图 6-2: 不同稀疏度  $K$  与噪声强度  $\sigma$  下, L1 支撑集恢复成功率随观测维度  $M$  的变化

图 6-3: 固定  $K = 8$  时, L1 与 L2 平均相对重建误差随观测维度  $M$  的变化对比图 6-4: 单次样例恢复对照 ( $M = 60, K = 8, \sigma = 0.02, n = 128$ )

## 7 结果分析与讨论

本章基于第 6 章生成的四类图表, 从稀疏恢复相变现象、三参数影响规律、与 RIP 理论下界的对比以及误差来源四个方面对仿真结果进行分析。

### 7.1 稀疏恢复相变现象

图 6-1 给出了无噪声情形 ( $\sigma = 0$ ) 下 L1 支撑集恢复成功率随观测维度  $M$  与稀疏度  $K$  变化的热力图。图中存在一条明显的相变带：在低  $M$ 、高  $K$  区域成功率接近于 0，随着  $M$  增大、 $K$  减小，成功率迅速过渡到接近 100%。例如，当  $K = 3$  时， $M = 20$  的成功率已达 92%， $M \geq 30$  后稳定为 100%；当  $K = 8$  时， $M = 30$  的成功率仅为 44%， $M = 40$  时跃升至 98%， $M \geq 50$  后保持 100%；当  $K = 20$  时， $M = 50$  的成功率仅为 12%， $M = 60$  时为 64%， $M = 70$  后才达到 100%。

若记临界观测维度  $M^*$  为成功率首次达到 100% 的最小  $M$ ，则  $M^*$  随  $K$  的增大而单调增大。图 6-2 的折线图进一步表明，固定  $K$  时成功率随  $M$  呈明显的 S 型上升； $K$  越大，整条曲线越向右移动，说明需要更多的观测才能实现可靠恢复。该现象与压缩感知理论中“存在相变临界值”的预期一致。

### 7.2 三参数影响规律

**稀疏度  $K$  的影响** 在相同噪声水平下， $K$  越大，达到可靠恢复所需的观测维度越高。以  $\sigma = 0$  为例， $K = 3$  在  $M = 30$  时即可达到 100% 成功率， $K = 8$  需要  $M = 40$ ，而  $K = 20$  需要  $M = 70$ 。这说明信号越稀疏，越容易从少量观测中恢复；稀疏度增加会显著提高恢复难度。

**观测维度  $M$  的影响** 随着  $M$  增大，支撑集恢复成功率总体上升，平均相对重建误差下降。在可恢复区域内，L1 方法的相对重建误差迅速降至接近 0（无噪声时可达  $10^{-4}$  量级以下）；而在欠采样区域，误差较高且恢复不稳定。

**噪声强度  $\sigma$  的影响** 噪声会同时降低成功率和重建精度。以  $K = 8$ 、 $M = 40$  为例， $\sigma = 0, 0.02, 0.05, 0.10$  时的 L1 成功率分别为 98%, 80%, 74%, 36%。图 6-3 显示，随着  $\sigma$  增大，L1 误差曲线在中等  $M$  区域的下降速度变慢，最终误差下限也被抬高；相变临界观测维度整体向右移动。

### 7.3 与 RIP 理论下界对比

RIP 理论给出稀疏恢复的充分条件<sup>[5]</sup>

$$M = O\left(K \log\left(\frac{n}{K}\right)\right), \quad (38)$$

需要强调的是，RIP 条件给出的是恢复的充分条件，且其针对的是测量矩阵满足 RIP 这一事件；高斯随机矩阵以很高概率满足 RIP。

本仿真观察到的相变现象与该理论的定性预言是吻合的：实现可靠恢复所需的观测数  $M^*$  随稀疏度  $K$  显著增大。同时噪声会进一步抬高实现支撑恢复所需要的观测规模。

### 7.4 误差与性能偏差来源分析

仿真结果与理论理想情况存在一定偏差，主要来源包括：

- **随机矩阵的 RIP 性质：** 高斯随机矩阵仅以高概率满足 RIP，并非每次随机试验都能保证恢复条件成立，因此个别试验可能失败；
- **观测噪声：** 噪声带来不可避免的重建误差，即使支撑集被正确恢复，相对重建误差也存在一个正的下界；
- **数值迭代精度：** FISTA 存在有限迭代次数和收敛阈值， $\lambda$  路径插值也只能近似满足残差约束  $\|Ax - y\|_2 = \delta$ ，这些都会引入微小数值误差；

- **L1 凸松弛的充分非必要性：**L1 松弛是 L0 问题的凸近似，存在部分信号无法通过 L1 精确恢复，这是方法本身的固有局限；
- **阈值选取：** $\delta$  取卡方分布的高概率上界，可能略大于真实噪声水平，导致约束偏松、解偏稀疏，也会影响恢复精度。

这些因素共同造成了成功率并非严格 0/1 跳变、而是呈现过渡带的现象，也解释了 L1 与 L2 基线之间的显著性能差异。

## 8 结论

本文围绕带噪声稀疏信号恢复问题，从理论、算法和实验三个层面完成了对 L1 凸松弛压缩感知恢复方案的系统研究。

在理论层面，本文建立了带噪声稀疏恢复的约束优化模型，推导了 L1 凸松弛问题的 KKT 条件，验证了 Slater 约束规格与强对偶性，为后续算法设计提供了理论基础。

在算法层面，本文未使用现成凸优化求解器，自主实现了 FISTA 加速近端梯度算法；针对约束形式 L1 恢复，设计了  $\lambda$  几何递减序列与残差曲线插值策略，稳健匹配残差约束  $\delta$ ；同时采用解析伪逆作为 L2 最小范数基线，保证对比公平并降低计算开销。

在实验层面，本文在  $n = 128$  的参数网格上进行了大规模仿真，分析了观测维度  $M$ 、稀疏度  $K$  与噪声强度  $\sigma$  对恢复性能的影响。结果表明：

- L1 恢复存在明显的相变现象，存在临界观测维度  $M^*$ ，当  $M$  超过  $M^*$  时支撑集恢复成功率快速趋近 100%；
- 稀疏度  $K$  越大，所需观测维度越高；噪声强度  $\sigma$  越大，相变临界右移，重建误差上升；
- 与 L2 最小范数基线相比，L1 方法在支撑集恢复成功率和相对重建误差两个指标上均显著占优，验证了稀疏先验在欠定线性逆问题中的关键作用。

综上，本文从理论推导、自研算法到数值实验，完整验证了 L1 凸松弛结合 FISTA 的稀疏恢复方案的有效性与稳健性。

## 参考文献

- [1] D. L. Donoho. Compressed sensing. *IEEE Transactions on Information Theory*, 52(4):1289–1306, 2006.
- [2] E. J. Candès, J. K. Romberg, and T. Tao. Stable signal recovery from incomplete and inaccurate measurements. *Communications on Pure and Applied Mathematics*, 59(8):1207–1223, 2006.
- [3] S. Boyd and L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004.
- [4] A. Beck and M. Teboulle. A fast iterative shrinkage-thresholding algorithm for linear inverse problems. *SIAM Journal on Imaging Sciences*, 2(1):183–202, 2009.
- [5] E. J. Candès and T. Tao. Decoding by linear programming. *IEEE Transactions on Information Theory*, 51(12):4203–4215, 2005.