

L1 凸松弛压缩感知信号恢复

1 摘要

压缩感知理论指出，当信号具有稀疏性或可压缩性时，可以通过远低于奈奎斯特率的线性测量以高概率恢复原始信号。最直接的 L0 稀疏恢复问题是 NP-难的组合优化问题，本文引入 L1 凸松弛将其转化为凸优化问题，并围绕带噪声稀疏信号恢复展开研究。

本文不调用任何商用凸优化求解器，自主实现了 FISTA 加速近端梯度算法；针对约束形式 L1 恢复问题，设计了 λ 几何递减序列与残差曲线插值策略，稳健匹配残差约束 δ ；同时采用解析伪逆作为 L2 最小范数基线，保证对比公平并降低计算开销。

在仿真实验中，本文系统分析了采样维度 M 、稀疏度 K 与噪声强度 σ 对重建性能的影响。结果表明：观测维度存在明显的相变临界值，当 M 超过临界值时支撑集恢复成功率快速趋近 100%；噪声会抬升临界采样规模并降低重建精度；L1 凸松弛恢复效果显著优于 L2 最小范数基线。

关键词：压缩感知；L1 凸松弛；FISTA；稀疏恢复；相变现象；KKT 条件

2 引言

奈奎斯特采样定理指出，要无失真地重建带限信号，采样率不得低于信号最高频率的两倍。然而在许多实际场景中，信号本身具有稀疏性或可压缩性，传统均匀采样方式获取了大量冗余数据，采样与存储成本高昂。压缩感知理论表明，对于稀疏信号，可以通过远低于奈奎斯特率的线性测量以高概率精确恢复，其核心在于利用信号的稀疏结构^[1]。

考虑 K -稀疏信号 $x \in \mathbb{R}^n$ （即至多 K 个非零分量），通过测量矩阵 $A \in \mathbb{R}^{M \times n}$ （ $M < n$ ）得到观测 $y = Ax$ 。理论上最直接的恢复模型是 L0 范数极小化

$$\min_{x \in \mathbb{R}^n} \|x\|_0 \quad \text{s.t.} \quad Ax = y,$$

但该问题是 NP-难的组合优化问题，难以大规模精确求解。L1 凸松弛将 L0 范数替换为 L1 范数，得到凸优化问题，从而能够高效求解，并在一定条件下保证恢复精度^[2]。

在现有课程作业或朴素实现中，常见以下几类简化缺陷：

- 直接对正则参数 λ 二分搜索，忽略残差函数 $r(\lambda)$ 单调非减但非严格单调、以及离散路径数值误差带来的失效风险；
- L2 基线采用迭代梯度投影，收敛缓慢且引入额外数值误差；
- 使用固定阈值 $|x_i| > \tau$ 判定支撑集，噪声环境下易漏判、误判；
- 使用未加速的 ISTA，收敛速度慢，批量仿真耗时高。

本项目针对上述问题，设计并实现稳健的约束 L1 恢复方案：自研 FISTA 求解 LASSO，采用 λ 几何序列与插值策略匹配残差约束，使用解析伪逆作为 L2 对照基线，并采用 Top-K 集合相等判定支撑集恢复成功率。

本项目的研究目标分为四层：

1. **理论**: 推导约束优化模型的 KKT 条件, 理解 L1 凸松弛的可行性与最优性;
2. **算法**: 自研 FISTA 求解 LASSO, 并设计稳健的 λ 寻根策略实现约束形式 L1 恢复;
3. **实验**: 定量分析观测维度 M 、稀疏度 K 、噪声强度 σ 对重建性能的影响, 观测相变现象;
4. **对比**: 与解析 L2 最小范数基线进行对照, 结合 RIP 理论分析仿真结果。

3 问题建模与凸优化理论基础

本章研究带噪声稀疏信号恢复问题, 依次建立信号观测模型、L0 稀疏恢复的 L1 凸松弛模型, 推导其 KKT 条件, 并给出对偶问题与强对偶性结论。

3.1 信号观测模型

研究问题为带噪声稀疏信号恢复。设原始信号 $x_{\text{true}} \in \mathbb{R}^n$ 是 K -稀疏信号 (即至多 K 个非零分量), 通过高斯随机测量矩阵 $A \in \mathbb{R}^{M \times n}$ 得到观测向量 $y \in \mathbb{R}^M$, 观测过程受到高斯噪声 $e \sim \mathcal{N}(0, \sigma^2 I_M)$ 污染:

$$y = Ax_{\text{true}} + e, \quad e \sim \mathcal{N}(0, \sigma^2 I_M). \quad (1)$$

各符号含义见表 1。

符号	含义
$x_{\text{true}} \in \mathbb{R}^n$	K -稀疏原始信号
$A \in \mathbb{R}^{M \times n}$	高斯随机测量矩阵, $M < n$
$e \in \mathbb{R}^M$	高斯观测噪声, $e \sim \mathcal{N}(0, \sigma^2 I_M)$
$y \in \mathbb{R}^M$	观测向量
K	原始信号稀疏度
M	观测维度

表 1: 符号说明

3.2 L0 稀疏恢复与 L1 凸松弛

无噪声 L0 恢复模型 在无噪声情形下, 稀疏恢复问题可写为如下 L0 范数极小化问题:

$$\min_{x \in \mathbb{R}^n} \|x\|_0 \quad \text{s.t.} \quad Ax = y, \quad (2)$$

其中 $\|x\|_0$ 表示向量 x 中非零分量的个数。

带噪声约束 L0 恢复模型 现实观测必然含有噪声, 等式约束 $Ax = y$ 无法严格满足, 因此将其替换为残差约束 $\|Ax - y\|_2 \leq \delta$, 得到带噪声约束的 L0 模型:

$$\min_{x \in \mathbb{R}^n} \|x\|_0 \quad \text{s.t.} \quad \|Ax - y\|_2 \leq \delta. \quad (3)$$

然而, L0 范数非凸、不连续, 对应的组合优化问题难以大规模精确求解, 因此考虑将 L0 范数凸松弛为 L1 范数。

L1 凸松弛问题 将 (3) 中的 $\|x\|_0$ 替换为 $\|x\|_1$, 得到核心优化问题

$$(P) \quad \min_{x \in \mathbb{R}^n} \|x\|_1 \quad \text{s.t.} \quad \|Ax - y\|_2 \leq \delta. \quad (4)$$

凸性论证 问题 (4) 中, 目标函数 $\|x\|_1$ 是凸函数; 约束函数 $\|Ax - y\|_2$ 是凸函数, 因此可行域

$$\{x \in \mathbb{R}^n : \|Ax - y\|_2 \leq \delta\}$$

是凸集。于是问题 (4) 是一个凸优化问题, 其局部最优解等价于全局最优解^[3]。

噪声阈值 δ 的选取 对于观测模型 (1), 残差向量

$$r = Ax - y = A(x - x_{\text{true}}) - e.$$

当 $x = x_{\text{true}}$ 时, 真实残差满足

$$r_{\text{true}} = -e \sim \mathcal{N}(0, \sigma^2 I_M).$$

标准化得 $\frac{1}{\sigma} r_{\text{true}} \sim \mathcal{N}(0, I_M)$, 于是

$$Z = \frac{1}{\sigma^2} \|r_{\text{true}}\|_2^2 = \frac{1}{\sigma^2} \|e\|_2^2 \sim \chi^2(M). \quad (5)$$

由卡方分布的高概率上界, 可取

$$\delta = \sigma \sqrt{M + 2\sqrt{2M}}. \quad (6)$$

δ 的取值影响可行域大小: 取得过小可能导致可行域为空, 取得过大会使约束过于松弛, 解过度稀疏、失真严重。

3.3 KKT 条件推导

对于凸优化问题 (4), 构造拉格朗日函数

$$L(x, \lambda) = \|x\|_1 + \lambda(\|Ax - y\|_2 - \delta), \quad \lambda \geq 0. \quad (7)$$

由于 $\|x\|_1$ 在原点不可微, 稳定性条件中的梯度应替换为次梯度。 $\|x\|_1$ 的次微分为

$$\partial\|x\|_1 = \{s \in \mathbb{R}^n : s_i \in \partial|x_i|, i = 1, \dots, n\}, \quad (8)$$

其中

$$\partial|x_i| = \begin{cases} \{1\}, & x_i > 0, \\ \{-1\}, & x_i < 0, \\ [-1, 1], & x_i = 0. \end{cases} \quad (9)$$

当 $\|Ax - y\|_2 \neq 0$ 时, $\|Ax - y\|_2$ 可微, 其次梯度即梯度

$$\partial_x \|Ax - y\|_2 = \frac{A^T(Ax - y)}{\|Ax - y\|_2}. \quad (10)$$

因此, 若 x^* 是问题 (4) 的最优解, 则存在乘子 $\lambda^* \geq 0$, 使得如下 KKT 条件成立:

1. 稳定性条件 (次梯度最优性):

$$-\lambda^* \frac{A^T(Ax^* - y)}{\|Ax^* - y\|_2} \in \partial\|x^*\|_1. \quad (11)$$

2. 原问题可行:

$$\|Ax^* - y\|_2 \leq \delta.$$

3. 对偶可行:

$$\lambda^* \geq 0.$$

4. 互补松弛:

$$\lambda^*(\|Ax^* - y\|_2 - \delta) = 0. \quad (12)$$

互补松弛条件说明：若 $\lambda^* > 0$ ，则必有 $\|Ax^* - y\|_2 = \delta$ ，即最优解位于约束边界上，约束被激活；若 $\lambda^* = 0$ ，则约束不起作用，问题退化为无约束极小化 $\|x\|_1$ 。在 Slater 条件成立时（见第 3.4 节），上述 KKT 条件也是全局最优的充分条件。

3.4 对偶问题与强对偶性

对偶函数推导 由拉格朗日函数 (7)，定义对偶函数

$$g(\lambda) = \inf_{x \in \mathbb{R}^n} L(x, \lambda) = -\lambda\delta + \inf_{x \in \mathbb{R}^n} (\|x\|_1 + \lambda\|Ax - y\|_2), \quad \lambda \geq 0. \quad (13)$$

利用范数的共轭表示 $\|z\|_2 = \sup_{\|u\|_2 \leq 1} u^T z$ ，并交换 $\inf$ 与 $\sup$ （由 Slater 条件保证其合理性），可得

$$\inf_{x \in \mathbb{R}^n} (\|x\|_1 + \lambda\|Ax - y\|_2) = \sup_{\|u\|_2 \leq 1} \left(-\lambda u^T y + \inf_{x \in \mathbb{R}^n} (\|x\|_1 + \lambda(A^T u)^T x) \right). \quad (14)$$

由于

$$\inf_{x \in \mathbb{R}^n} (\|x\|_1 + z^T x) = \begin{cases} 0, & \|z\|_\infty \leq 1, \\ -\infty, & \text{否则}, \end{cases}$$

令 $v = \lambda u$ ，则

$$g(\lambda) = -\lambda\delta + \sup_{\|v\|_2 \leq \lambda, \|A^T v\|_\infty \leq 1} (-v^T y). \quad (15)$$

于是拉格朗日对偶问题为

$$\max_{\lambda \geq 0} g(\lambda) = \max_{\lambda \geq 0, \|v\|_2 \leq \lambda, \|A^T v\|_\infty \leq 1} (-\delta\lambda - v^T y). \quad (16)$$

对固定的 v ，由于 $\delta > 0$ ，最优的 λ 取 $\lambda = \|v\|_2$ ，故 (16) 等价于

$$\min_{v \in \mathbb{R}^M} y^T v + \delta\|v\|_2 \quad \text{s.t.} \quad \|A^T v\|_\infty \leq 1. \quad (17)$$

记 (17) 的最优值为 q^* ，拉格朗日对偶问题 (16) 的最优值为 d^* ，则有 $d^* = -q^*$ ；强对偶成立时，原问题最优值 p^* 满足 $p^* = d^* = -q^*$ 。

Slater 条件验证 约束函数 $\|Ax - y\|_2$ 是凸函数。当 $\delta > 0$ 且 A 行满秩时（高斯随机矩阵以概率 1 行满秩），方程 $Ax = y$ 有解，因此存在严格可行点 x 满足 $\|Ax - y\|_2 = 0 < \delta$ ，Slater 条件成立。当 $\delta = 0$ （即无噪声情形）时，可行域退化为仿射集 $\{x : Ax = y\}$ ，强对偶性仍可由线性约束凸优化理论保证，也可视为 $\delta \downarrow 0$ 的极限情形。

强对偶结论 综上，问题 (4) 满足约束规格，强对偶成立，原问题与对偶问题之间存在确定的最优值对应关系；这一性质为后续设计自研求解器与验证最优性提供了理论基础。

4 自研求解器：加速近端梯度算法 (FISTA)

本章针对约束问题 (4)，给出其等价 LASSO 形式与 λ 寻根策略，推导近端算子与软阈值公式，并建立 ISTA/FISTA 迭代算法及收敛性分析。

4.1 约束问题等价转化与 λ 寻根策略

原约束问题 (4) 可等价地表述为：存在参数 $\lambda > 0$ ，使得 LASSO 问题

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - y\|_2^2 + \lambda \|x\|_1 \quad (18)$$

的最优解 x_λ 同时满足残差约束

$$\|Ax_\lambda - y\|_2 = \delta.$$

残差函数 $r(\lambda) = \|Ax_\lambda - y\|_2$ 关于 λ 单调非减，但可能存在非严格单调区间；在有限迭代和离散 λ -path 下，直接求解精确 λ 还存在数值误差，因此采用几何路径 + 插值策略：构造 λ 的几何递减序列，上限取 $\|A^T y\|_\infty$ ，下限取 $10^{-6} \|A^T y\|_\infty$ ；对每个 λ 求解 LASSO (18)，得到残差曲线 $r(\lambda)$ ，再利用插值方法寻找满足 $r(\lambda) = \delta$ 的目标 λ 。

4.2 近端算子理论推导

对于闭凸函数 $f: \mathbb{R}^n \rightarrow (-\infty, +\infty]$ ，给定参数 $\tau > 0$ ，近端算子定义为

$$\text{prox}_{\tau f}(v) = \arg \min_{x \in \mathbb{R}^n} \left\{ f(x) + \frac{1}{2\tau} \|x - v\|_2^2 \right\}. \quad (19)$$

其含义是在尽量保持 x 接近 v 的同时使 $f(x)$ 尽量小。

对 LASSO 问题 (18)，令

$$g(x) = \frac{1}{2} \|Ax - y\|_2^2, \quad h(x) = \lambda \|x\|_1,$$

则目标函数为 $g(x) + h(x)$ ，其中 g 可微、 h 不可微但凸。采用“梯度下降处理 g 、近端算子处理 h ”的策略。

考虑 $h(x) = \lambda \|x\|_1$ ，由定义 (19) 得

$$\text{prox}_{\tau h}(v) = \arg \min_{x \in \mathbb{R}^n} \left\{ \tau \lambda \|x\|_1 + \frac{1}{2} \|x - v\|_2^2 \right\}. \quad (20)$$

将目标函数写开：

$$\frac{1}{2} \|x - v\|_2^2 + \tau \lambda \|x\|_1 = \sum_{i=1}^n \left[\frac{1}{2} (x_i - v_i)^2 + \tau \lambda |x_i| \right].$$

因此 n 维问题可分解为 n 个独立的一维问题。对标量问题

$$\min_{u \in \mathbb{R}} \phi(u) = \frac{1}{2} (u - v)^2 + \alpha |u|,$$

其中记 $\alpha = \tau \lambda$ 。由于 $|u|$ 在 0 处不可微，分情况讨论：

- 若 $u > 0$ ，则 $\phi(u) = \frac{1}{2} (u - v)^2 + \alpha u$ ，令 $\phi'(u) = u - v + \alpha = 0$ ，得 $u^* = v - \alpha$ ，需满足 $v > \alpha$ ；
- 若 $u < 0$ ，则 $\phi(u) = \frac{1}{2} (u - v)^2 - \alpha u$ ，令 $\phi'(u) = u - v - \alpha = 0$ ，得 $u^* = v + \alpha$ ，需满足 $v < -\alpha$ ；
- 若 $u = 0$ ，由次梯度 $\partial|u|_{u=0} = [-1, 1]$ ，最优性条件 $0 \in \partial\phi(0) = -v + \alpha[-1, 1]$ ，即 $-\alpha \leq v \leq \alpha$ 。

综合得分段解

$$u^* = \begin{cases} v - \alpha, & v > \alpha, \\ 0, & |v| \leq \alpha, \\ v + \alpha, & v < -\alpha. \end{cases} \quad (21)$$

回代 $\alpha = \tau \lambda$ 并写成符号函数形式，即得软阈值算子

$$S_{\tau \lambda}(v) = \text{sign}(v) \max\{|v| - \tau \lambda, 0\}. \quad (22)$$

对向量逐元素作用，有

$$\text{prox}_{\tau \lambda \|\cdot\|_1}(v) = (S_{\tau \lambda}(v_1), \dots, S_{\tau \lambda}(v_n))^T. \quad (23)$$

4.3 ISTA 与 FISTA 迭代算法

近端梯度迭代格式 对光滑部分 g 在 x_k 处作一阶近似，并加上邻近项以保证数值稳定性：

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ g(x_k) + \nabla g(x_k)^T (x - x_k) + \frac{1}{2t} \|x - x_k\|_2^2 + h(x) \right\}, \quad (24)$$

其中 $t > 0$ 为步长。配方并略去与 x 无关的常数项，可得

$$x_{k+1} = \text{prox}_{th}(x_k - t\nabla g(x_k)).$$

对于 $h(x) = \lambda\|x\|_1$ ，有 $\text{prox}_{th}(v) = S_{t\lambda}(v)$ ，且 $\nabla g(x) = A^T(Ax - y)$ ，因此 ISTA 迭代格式为

$$x_{k+1} = S_{t\lambda}(x_k - tA^T(Ax_k - y)). \quad (25)$$

步长取 $0 < t \leq 1/L$ ，其中 $L = \|A\|_2^2$ 是 ∇g 的 Lipschitz 常数，见下文收敛性分析。

FISTA 加速 ISTA 每一步只利用当前点 x_k 的信息，收敛速度较慢。FISTA 引入 Nesterov 外推点 y_k 加速：

$$x_{k+1} = \text{prox}_{th}(y_k - t\nabla g(y_k)). \quad (26)$$

辅助序列 t_k 与外推点更新为

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad (27)$$

$$y_{k+1} = x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k). \quad (28)$$

通常取初值 $t_1 = 1, y_1 = x_0$ 。FISTA 在目标函数值意义下具有 $O(1/k^2)$ 的收敛率^[4]，相比 ISTA 的 $O(1/k)$ （见后文 ISTA 收敛性）有本质加速。

步长选取 g 的梯度 Lipschitz 常数为

$$\|\nabla g(x) - \nabla g(z)\|_2 = \|A^T A(x - z)\|_2 \leq \|A^T A\|_2 \|x - z\|_2,$$

故 $L = \|A^T A\|_2 = \|A\|_2^2$ 。步长可取 $t = 1/L = 1/\|A\|_2^2$ ，其中 $\|A\|_2^2$ 通过计算 $A^T A$ 的最大特征值得到。

ISTA 收敛性 设 x^* 为问题 (18) 的最优解， $F(x) = g(x) + h(x)$ 。由 g 的 Lipschitz 梯度性质，当 $t \leq 1/L$ 时，

$$g(x) \leq g(z) + \nabla g(z)^T (x - z) + \frac{1}{2t} \|x - z\|_2^2. \quad (29)$$

定义代理函数

$$Q_t(x, z) = g(z) + \nabla g(z)^T (x - z) + \frac{1}{2t} \|x - z\|_2^2 + h(x), \quad (30)$$

则 $F(x) \leq Q_t(x, z)$ ，且 ISTA 更新 (25) 等价于 $x_{k+1} = \arg \min_x Q_t(x, x_k)$ 。由最优性条件，存在 $s_{k+1} \in \partial h(x_{k+1})$ 使得

$$\nabla g(x_k) + \frac{1}{t}(x_{k+1} - x_k) + s_{k+1} = 0.$$

由 h 的凸性可得

$$h(x_{k+1}) - h(x) \leq -\nabla g(x_k)^T (x_{k+1} - x) - \frac{1}{t}(x_{k+1} - x_k)^T (x_{k+1} - x),$$

由 g 的凸性与 (29) 可得

$$g(x_{k+1}) - g(x) \leq \nabla g(x_k)^T (x_{k+1} - x) + \frac{1}{2t} \|x_{k+1} - x_k\|_2^2.$$

两式相加并利用恒等式

$$2(a-b)^T(a-c) = \|a-b\|_2^2 + \|a-c\|_2^2 - \|b-c\|_2^2$$

整理得

$$F(x_{k+1}) - F(x) \leq \frac{1}{2t} (\|x_k - x\|_2^2 - \|x_{k+1} - x\|_2^2). \quad (31)$$

令 $x = x^*$ 并对 $k = 0, \dots, N-1$ 求和, 利用 Telescoping 求和得

$$\sum_{k=0}^{N-1} (F(x_{k+1}) - F^*) \leq \frac{1}{2t} \|x_0 - x^*\|_2^2.$$

又因 $F(x_k)$ 单调不增, 故

$$F(x_N) - F^* \leq \frac{1}{N} \sum_{k=0}^{N-1} (F(x_{k+1}) - F^*) \leq \frac{\|x_0 - x^*\|_2^2}{2tN}.$$

因此

$$F(x_N) - F^* = O\left(\frac{1}{N}\right), \quad (32)$$

即 ISTA 具有 $O(1/k)$ 收敛率。

停机准则 采用双重停机准则:

- 相对迭代变化:

$$r_x^{(k)} = \frac{\|x_{k+1} - x_k\|_2}{\max(1, \|x_k\|_2)} < 10^{-5};$$

- 相对目标函数变化:

$$r_F^{(k)} = \frac{|F_{k+1} - F_k|}{\max(1, |F_k|)} < 10^{-8};$$

- 当迭代次数达到 $k_{\max} = 500$ 时强制停机。

前两项同时满足时认为算法收敛; 若达到最大迭代次数仍未满足, 则强制终止并保留当前迭代解。

4.4 L2 基线求解方案

为了公平对比 L1 凸松弛方法的效果, 本节实现一个 L2 最小范数基线求解器。其对比优化模型为

$$\min_{x \in \mathbb{R}^n} \|x\|_2 \quad \text{s.t.} \quad \|Ax - y\|_2 \leq \delta. \quad (33)$$

该模型不利用稀疏性, 仅寻找能量最小的可行解, 作为实验中的朴素对照。

解析伪逆闭式解 需要说明的是, 问题 (33) 的最优解通常位于可行域边界 $\|Ax - y\|_2 = \delta$ 上, 并不等于等式约束 $Ax = y$ 下的最小范数解。但在欠定情形 $M < n$ 且 A 行满秩时, $Ax = y$ 有解, 此时可取等式约束最小范数解

$$\hat{x}_{L2} = A^T(AA^T)^{-1}y \quad (34)$$

作为 L2 基线的简化实现。该解残差为零, 恒满足 $\|A\hat{x}_{L2} - y\|_2 \leq \delta$, 因而是 (33) 的一个可行解; 虽然它不一定是最优解, 但不利用稀疏性、计算简单、对比公平, 足以作为朴素对照。相比原始方案中的梯度投影迭代, 解析伪逆具有以下优点:

- 闭式求解, 计算开销低;
- 不引入迭代收敛误差, 保证对比公平;
- 在欠定行满秩情形下, 伪逆解恒满足残差约束 $\|A\hat{x}_{L2} - y\|_2 \leq \delta$ 。

可行性讨论 当 A 行满秩时, $Ax = y$ 有解, 因此 $\hat{x}_{L2}$ 的残差为零, 对任意 $\delta \geq 0$ 均可行。若因数值或退化情形导致残差超过 δ , 理论上可启用投影策略, 但本实验场景直接使用解析解, 以保证 L2 基线的实现简单且公平。

5 仿真实验方案设计

本章规定批量仿真实验的完整方案, 包括参数网格、噪声阈值、评价指标、单次实验流程与数据保存方式, 为后续实验运行和结果分析提供统一标准。

5.1 实验参数汇总

固定参数: 信号长度 $n = 128$ 。变量网格如表 2 所示。

参数	取值
观测维度 M	20, 30, 40, 50, 60, 70, 80, 90, 100
稀疏度 K	3, 5, 8, 12, 16, 20
噪声标准差 σ	0, 0.02, 0.05, 0.10
每组随机试验次数	50

表 2: 实验参数网格

每组参数 (M, K, σ) 独立重复 50 次随机试验。

5.2 噪声阈值 δ 选取规则

由第 3.1 节的分析, 取

$$\delta = \sigma \sqrt{M + 2\sqrt{2M}}. \quad (35)$$

该阈值来自卡方分布 $\chi^2(M)$ 的高概率上界, 使真实残差以较高概率满足约束。 δ 的取值影响可行域大小: 取得过小可能导致可行域为空; 取得过大会使约束过于松弛, 解过度稀疏、失真严重。特别地, 当 $\sigma = 0$ 时 $\delta = 0$, 对应无噪声情形下的精确约束 $Ax = y$ 。

5.3 评价指标定义

支撑集恢复成功率 已知真实稀疏度 K 。对重建向量 $\hat{x}$, 取绝对值最大的前 K 个坐标构成估计支撑集

$$\hat{S} = \arg \max_{|S|=K} \sum_{i \in S} |\hat{x}_i|, \quad (36)$$

即若

$$|\hat{x}_{i_1}| \geq |\hat{x}_{i_2}| \geq \cdots \geq |\hat{x}_{i_K}| \geq \max_{j \notin \hat{S}} |\hat{x}_j|,$$

则

$$\hat{S} = \{i_1, i_2, \dots, i_K\}.$$

将估计支撑集 $\hat{S}$ 与真实支撑集 S_{true} 做集合相等判定, 单次试验成功当且仅当 $\hat{S} = S_{\text{true}}$ 。禁止使用固定阈值 $|\hat{x}_i| > \tau$ 判定支撑集, 因为噪声环境下固定阈值会产生漏判和误判。

相对重建误差 相对重建误差定义为

$$RE = \frac{\|\hat{x} - x_{\text{true}}\|_2}{\|x_{\text{true}}\|_2}. \quad (37)$$

RE 仅作为连续量化指标, 不作为支撑集成功判定标准。

5.4 单次完整实验流程

对每一组参数 (M, K, σ) 和每一次随机试验，按以下步骤执行：

1. 生成 K -稀疏原始信号 $x_{\text{true}} \in \mathbb{R}^n$ ：随机选取 K 个支撑位置，非零分量独立服从标准正态分布；
2. 生成高斯随机测量矩阵 $A \in \mathbb{R}^{M \times n}$ ，元素独立服从标准正态分布；
3. 生成高斯噪声 $e \sim \mathcal{N}(0, \sigma^2 I_M)$ ，构造观测向量

$$y = Ax_{\text{true}} + e;$$

4. 按 (35) 计算 δ ，使用第 4.1 节的 FISTA+LASSO 路径插值方法求解约束 L1 恢复问题 (4)，得到 $\hat{x}_{L1}$ ；
5. 使用第 4.4 节的解析伪逆最小范数解作为 L2 基线（等式约束近似）

$$\hat{x}_{L2} = A^T(AA^T)^{-1}y;$$

6. 分别计算 $\hat{x}_{L1}$ 、 $\hat{x}_{L2}$ 的支撑集恢复结果与相对重建误差 (37)；
7. 重复上述过程 50 次，统计支撑集恢复成功率与平均相对重建误差。

5.5 统计量与数据保存

对每组参数 (M, K, σ) ，统计以下指标：

- 支撑集恢复成功率：50 次试验中 $\hat{S} = S_{\text{true}}$ 的次数占比；
- 平均相对重建误差：50 次试验的 RE 均值，L1 与 L2 分别统计。

将最终统计结果保存为 `.npy` 文件，避免重复运算。



5.6 代码实现模块



实验代码按以下模块组织：

- `FISTA.py`：自研 FISTA 求解 LASSO；
- `lasso.py`：基于 FISTA 的 λ 几何序列与插值寻根，求解约束 L1 问题；
- `l2_baseline.py`：L2 基线解析伪逆求解；
- `experiment.py`：参数网格三层循环、50 次随机试验、指标统计与结果保存。

6 实验结果可视化

本章展示四类实验结果图表：无噪声相变热力图、支撑恢复成功率随观测维度变化折线图、L1 与 L2 平均相对重建误差对比图，以及单次样例恢复对照图。

图 6-1: 无噪声情形 ($\sigma = 0$) 下 L1 支撑集恢复成功率热力图图 6-2: 不同稀疏度 K 与噪声强度 σ 下, L1 支撑集恢复成功率随观测维度 M 的变化

图 6-3: 固定 $K = 8$ 时, L1 与 L2 平均相对重建误差随观测维度 M 的变化对比图 6-4: 单次样例恢复对照 ($M = 60, K = 8, \sigma = 0.02, n = 128$)

7 结果分析与讨论

本章基于第 6 章生成的四类图表, 从稀疏恢复相变现象、三参数影响规律、与 RIP 理论下界的对比以及误差来源四个方面对仿真结果进行分析。

7.1 稀疏恢复相变现象

图 6-1 给出了无噪声情形 ($\sigma = 0$) 下 L1 支撑集恢复成功率随观测维度 M 与稀疏度 K 变化的热力图。图中存在一条明显的相变带：在低 M 、高 K 区域成功率接近于 0，随着 M 增大、 K 减小，成功率迅速过渡到接近 100%。例如，当 $K = 3$ 时， $M = 20$ 的成功率已达 92%， $M \geq 30$ 后稳定为 100%；当 $K = 8$ 时， $M = 30$ 的成功率仅为 44%， $M = 40$ 时跃升至 98%， $M \geq 50$ 后保持 100%；当 $K = 20$ 时， $M = 50$ 的成功率仅为 12%， $M = 60$ 时为 64%， $M = 70$ 后才达到 100%。

若记临界观测维度 M^* 为成功率首次达到 100% 的最小 M ，则 M^* 随 K 的增大而单调增大。图 6-2 的折线图进一步表明，固定 K 时成功率随 M 呈明显的 S 型上升； K 越大，整条曲线越向右移动，说明需要更多的观测才能实现可靠恢复。该现象与压缩感知理论中“存在相变临界值”的预期一致。

7.2 三参数影响规律

稀疏度 K 的影响 在相同噪声水平下， K 越大，达到可靠恢复所需的观测维度越高。以 $\sigma = 0$ 为例， $K = 3$ 在 $M = 30$ 时即可达到 100% 成功率， $K = 8$ 需要 $M = 40$ ，而 $K = 20$ 需要 $M = 70$ 。这说明信号越稀疏，越容易从少量观测中恢复；稀疏度增加会显著提高恢复难度。

观测维度 M 的影响 随着 M 增大，支撑集恢复成功率总体上升，平均相对重建误差下降。在可恢复区域内，L1 方法的相对重建误差迅速降至接近 0（无噪声时可达 10^{-4} 量级以下）；而在欠采样区域，误差较高且恢复不稳定。

噪声强度 σ 的影响 噪声会同时降低成功率和重建精度。以 $K = 8$ 、 $M = 40$ 为例， $\sigma = 0, 0.02, 0.05, 0.10$ 时的 L1 成功率分别为 98%, 80%, 74%, 36%。图 6-3 显示，随着 σ 增大，L1 误差曲线在中等 M 区域的下降速度变慢，最终误差下限也被抬高；相变临界观测维度整体向右移动。

7.3 与 RIP 理论下界对比

RIP 理论给出稀疏恢复的充分条件^[5]

$$M \geq CK \log \left(\frac{n}{K} \right), \quad (38)$$

其中 C 为常数。需要强调的是，RIP 条件给出的是恢复的充分条件，且其针对的是测量矩阵满足 RIP 这一事件；而实验中统计的是支撑集恢复成功率 $\Pr(\hat{S} = S_{\text{true}})$ ，两者并不是同一个随机变量或事件，因此不能直接从实验临界点反推出 RIP 常数 C 。

不过，可以基于经验恢复阈值对 $CK \log(n/K)$ 进行数量级比较。例如在无噪声热力图中，取成功率首次达到约 95% 以上的临界观测维度 M^* ，可观察到 M^* 随 K 增大而增大，且与 $K \log(n/K)$ 大致保持同一数量级：对 $K = 5, 8, 16, 20$ ， $M^*/(K \log(n/K))$ 分别约为 1.85, 1.80, 1.80, 1.89。这说明实验临界采样规模与 RIP 理论尺度一致，但上述比值不应被解释为对 RIP 常数 C 的估计。

此外，噪声会使所需 M 进一步增大，因此有噪声情形下的临界采样规模会整体右移。

7.4 误差与性能偏差来源分析

仿真结果与理论理想情况存在一定偏差，主要来源包括：

- **随机矩阵的 RIP 性质**：高斯随机矩阵仅以高概率满足 RIP，并非每次随机试验都能保证恢复条件成立，因此个别试验可能失败；
- **观测噪声**：噪声带来不可避免的重建误差，即使支撑集被正确恢复，相对重建误差也存在一个正的下界；

- **数值迭代精度**: FISTA 存在有限迭代次数和收敛阈值, λ 路径插值也只能近似满足残差约束 $\|Ax - y\|_2 = \delta$, 这些都会引入微小数值误差;
- **L1 凸松弛的充分非必要性**: L1 松弛是 L0 问题的凸近似, 存在部分信号无法通过 L1 精确恢复, 这是方法本身的固有局限;
- **阈值选取**: δ 取卡方分布的高概率上界, 可能略大于真实噪声水平, 导致约束偏松、解偏稀疏, 也会影响恢复精度。

这些因素共同造成了成功率并非严格 0/1 跳变、而是呈现过渡带的现象, 也解释了 L1 与 L2 基线之间的显著性能差异。

8 结论

本文围绕带噪声稀疏信号恢复问题, 从理论、算法和实验三个层面完成了对 L1 凸松弛压缩感知恢复方案的系统研究。

在理论层面, 本文建立了带噪声稀疏恢复的约束优化模型, 推导了 L1 凸松弛问题的 KKT 条件, 验证了 Slater 约束规格与强对偶性, 为后续算法设计提供了理论基础。

在算法层面, 本文未使用现成凸优化求解器, 自主实现了 FISTA 加速近端梯度算法; 针对约束形式 L1 恢复, 设计了 λ 几何递减序列与残差曲线插值策略, 稳健匹配残差约束 δ ; 同时采用解析伪逆作为 L2 最小范数基线, 保证对比公平并降低计算开销。

在实验层面, 本文在 $n = 128$ 的参数网格上进行了大规模仿真, 分析了观测维度 M 、稀疏度 K 与噪声强度 σ 对恢复性能的影响。结果表明:

- L1 恢复存在明显的相变现象, 存在临界观测维度 M^* , 当 M 超过 M^* 时支撑集恢复成功率快速趋近 100%;
- 稀疏度 K 越大, 所需观测维度越高; 噪声强度 σ 越大, 相变临界右移, 重建误差上升;
- 与 L2 最小范数基线相比, L1 方法在支撑集恢复成功率和相对重建误差两个指标上均显著占优, 验证了稀疏先验在欠定线性逆问题中的关键作用。

综上, 本文从理论推导、自研算法到数值实验, 完整验证了 L1 凸松弛结合 FISTA 的稀疏恢复方案的有效性与稳健性。

参考文献

- [1] D. L. Donoho. Compressed sensing. *IEEE Transactions on Information Theory*, 52(4):1289–1306, 2006.
- [2] E. J. Candès, J. K. Romberg, and T. Tao. Stable signal recovery from incomplete and inaccurate measurements. *Communications on Pure and Applied Mathematics*, 59(8):1207–1223, 2006.
- [3] S. Boyd and L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004.
- [4] A. Beck and M. Teboulle. A fast iterative shrinkage-thresholding algorithm for linear inverse problems. *SIAM Journal on Imaging Sciences*, 2(1):183–202, 2009.
- [5] E. J. Candès and T. Tao. Decoding by linear programming. *IEEE Transactions on Information Theory*, 51(12):4203–4215, 2005.