

增广拉格朗日惩罚参数 c 的数值敏感性研究

1 研究背景与核心研究问题

1.1 增广拉格朗日方法

增广拉格朗日方法 (Augmented Lagrangian Method, ALM) 是求解等式约束优化问题的经典框架^[1]。考虑如下等式约束优化问题

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{s.t.} \quad Ax = b, \quad (1)$$

其中 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为目标函数, $A \in \mathbb{R}^{m \times n}$ 为约束矩阵, $b \in \mathbb{R}^m$ 为约束右端项。ALM 在拉格朗日函数的基础上引入二次惩罚项, 构造增广拉格朗日函数

$$\mathcal{L}_c(x, \lambda) = f(x) + \lambda^\top (Ax - b) + \frac{c}{2} \|Ax - b\|_2^2, \quad (2)$$

其中 $c > 0$ 为惩罚参数, $\lambda \in \mathbb{R}^m$ 为拉格朗日乘子。ALM 的每次外层迭代先对 x 极小化 $\mathcal{L}_c(x, \lambda_k)$ 得到 x_{k+1} , 再按乘子更新规则

$$\lambda_{k+1} = \lambda_k + c(Ax_{k+1} - b) \quad (3)$$

更新乘子。该方法兼具拉格朗日法的对偶上升思想与罚函数法的强凸性, 在凸优化、约束优化和分布式优化等领域有广泛应用。

1.2 惩罚参数 c 的关键作用

在增广拉格朗日函数 (2) 中, 惩罚参数 c 是调控约束惩罚强度的核心超参数, 其取值直接影响算法的外层收敛速度与子问题求解难度:

- 当 c 较小时, 约束惩罚较弱, 乘子更新对约束违反的修正力度有限, 外层收敛通常较慢;
- 当 c 较大时, 约束惩罚增强, 外层收敛往往加快, 但子问题海森矩阵 $H_c = H + cA^\top A$ 的条件数随之增大, 内层求解难度与单轮计算成本上升。

因此, c 的选取本质上是在外层迭代步数与内层求解成本之间进行权衡, 理解这一权衡关系对 ALM 的高效实现和参数自适应具有重要意义。

1.3 现有研究的不足

现有研究多基于经验定性描述 c 的权衡效应, 但仍存在以下不足:

- 对“精确求解子问题”与“不精确求解子问题”两种场景下的行为差异缺乏系统区分, 容易将不精确求解带来的数值现象错误归因于 ALM 本身;
- 对最优惩罚参数与内层求解精度、原问题病态性的耦合关系缺少定量验证;
- 对计算意义上的最优惩罚参数 c^* 如何随问题条件数 $\kappa(H)$ 与内层精度 ϵ_{inner} 漂移, 尚未形成系统的实验结论。

这些不足使得实际使用中惩罚参数 c 的选取往往依赖人工试错, 缺乏可量化的指导准则。

1.4 核心研究问题

针对上述不足，本实验以对称正定二次规划为基准测试问题，系统控制惩罚参数、内层求解精度、原问题条件数三类变量，围绕以下三个核心研究问题（Research Question, RQ）展开：

1. **RQ1：**惩罚参数 c 如何影响 ALM 的外层收敛行为？聚焦 c 对原始残差 $\|Ax_k - b\|_2$ 与目标函数误差 $f(x_k) - f^*$ 演化规律的影响，并区分精确子问题求解与不精确子问题求解两种场景下的差异。
2. **RQ2：**惩罚参数 c 如何影响算法的整体计算效率？结合外层迭代开销与内层求解开销，量化二者的权衡关系，定位计算意义上的最优惩罚参数。
3. **RQ3：**惩罚参数的最优取值是否依赖于问题条件数与内层求解精度？检验 $c^* = c^*(\kappa(H), \epsilon_{\text{inner}})$ 的猜想，即最优惩罚参数是否同时由原问题条件数和内层求解精度决定，这是本实验最具创新性的核心内容。

2 理论基础与研究假设

本章围绕惩罚参数 c 的作用机制，给出精确 ALM 与不精确 ALM 的性质区分、子问题条件数的理论分析、内层迭代计算代价理论，并提出可检验的研究假设。

2.1 两类 ALM 的性质区分

本实验将 ALM 区分为两个层次：

1. **精确 ALM：**子问题求解到极高精度，近似理论意义上的全局最小化。在凸问题假设下，外层迭代具有严格收敛保证，目标函数与残差不会出现结构性震荡， c 仅影响外层收敛速率。
2. **不精确 ALM：**子问题仅求解到有限精度（固定迭代步数或固定容差）。此时大 c 会放大内层求解误差、加剧数值条件恶化，进而导致目标值波动、收敛平台抬高，甚至计算效率下降。

震荡、平台等现象本质来源于子问题不精确求解、数值条件恶化、浮点误差、终止准则不合理等实际因素，而非 ALM 本身的理论性质。

2.2 子问题条件数的理论分析

对于二次规划基准问题，子问题的海森矩阵为

$$H_c = H + cA^\top A. \quad (4)$$

若 $H \succ 0$ 且 A 行满秩，则有以下性质：

- 最大特征值 $\lambda_{\max}(H_c)$ 随 c 增大单调递增，当 $c \rightarrow \infty$ 时近似随 c 线性增长；
- 最小特征值 $\lambda_{\min}(H_c) \geq \lambda_{\min}(H) > 0$ ，存在严格正下界；
- 条件数 $\kappa(H_c) = \lambda_{\max}(H_c)/\lambda_{\min}(H_c)$ 的变化取决于 H 与 $A^\top A$ 的谱结构：由于 $A^\top A \succeq 0$ ，增大 c 会使 $\lambda_{\max}(H_c)$ 与 $\lambda_{\min}(H_c)$ 均单调不减，但二者增长速率一般不同，因此 $\kappa(H_c)$ 并不必然单调上升；在本实验的大 c 区域， $\kappa(H_c)$ 整体呈上升趋势。

该分析说明：增大 c 在加强约束惩罚的同时，会改变子问题的谱结构，通常（但并非必然）恶化数值条件，从而增加内层求解难度。实际变化需结合 H 与 $A^\top A$ 的谱方向综合判断。

2.3 内层迭代的计算代价理论

采用共轭梯度法 (CG) 求解子问题线性系统时, 经典收敛理论给出达到精度 ϵ_{inner} 所需迭代步数的上界^[2]:

$$N_{\text{CG}} \lesssim O\left(\sqrt{\kappa(H_c)} \cdot \log \frac{1}{\epsilon_{\text{inner}}}\right), \quad (5)$$

即内层迭代步数的上界与子问题条件数的平方根正相关, 与求解精度的对数正相关。结合式 (4) 的条件数性质, 可以预期 c 增大时单轮内层求解成本上升。

2.4 正式研究假设

基于上述理论, 提出以下可检验的研究假设:

1. **H1:** 随着 c 增大, 外层迭代中原始残差的收敛速率总体提升; 同时子问题条件数总体增大, 单轮子问题的求解成本呈上升趋势, 二者形成权衡关系。
2. **H2:** 在不精确 ALM 场景下, 总计算代价定义为总内层迭代数/运行时间, 如果总成本曲线存在内部最小值, 则称其表现为 U 型; 若最优点落在扫描边界, 则报告为边界最优。
3. **H3:** 精确 ALM 场景下, 外层收敛速度随 c 增大单调提升, 不会出现显著的 U 型效率拐点; 震荡与收敛平台仅在不精确 ALM 的大 c 区域出现。
4. **H4:** 最优惩罚参数依赖于内层求解精度; 随着内层求解精度变化, 计算成本最优区域将发生系统性漂移。
5. **H5:** 原问题条件数会影响惩罚参数的计算最优区域; 随着问题病态性增强, 大 c 所带来的内层条件恶化效应预计更加显著。

上述假设将指导后续实验设计与结果分析。

3 测试问题构造

3.1 基准二次规划问题

选取对称正定二次规划作为核心测试问题, 其优势在于子问题结构显式、条件数可精确计算、最优解可通过 KKT 系统精确求解:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top H x - q^\top x \quad \text{s.t.} \quad A x = b, \quad (6)$$

其中 $H \succ 0$ 为对称正定矩阵, $q \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ 。基础参数设置如下:

- 问题规模: 变量维数 $n = 100$, 约束个数 $m = 20$;
- A : 随机稠密矩阵, 保证行满秩;
- b : 通过预设最优解 x^* 反算生成, 确保可行且最优值、最优乘子已知, 用于误差计算。

3.2 多条件数测试集

构造 4 组不同条件数的 H 矩阵, 作为独立实验因素:

$$\kappa(H) \in \{10^1, 10^2, 10^3, 10^4\}, \quad (7)$$

用于研究原问题病态性与惩罚参数 c 的耦合效应。

4 实验变量与控制规范

注. 本章为实验变量与控制规范说明, 用于保证实验可重复性, 不涉及理论推导与算法实现代码; 若报告聚焦理论与算法主线, 可将本章作为可选内容酌情精简或忽略。

4.1 核心实验因素

1. 惩罚参数 c : 对数等间距选取 9 个值, 覆盖 9 个数量级

$$c \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 10^0, 10^1, 10^2, 10^3, 10^4\}.$$

2. 内层求解精度 ϵ_{inner} : 选取 3 个典型精度等级, 额外设置高精度组作为精确 ALM 近似

$$\epsilon_{\text{inner}} \in \{10^{-2}, 10^{-4}, 10^{-6}, 10^{-12}\}.$$

3. 原问题条件数 $\kappa(H)$: 4 个梯度等级

$$\kappa(H) \in \{10^1, 10^2, 10^3, 10^4\}.$$

4.2 统一控制变量

为保证单一变量原则, 所有实验组采用一致的基础设置:

- 初始点: $x_0 = \mathbf{0}$;
- 初始乘子: $\lambda_0 = \mathbf{0}$;
- 外层终止准则: 原始残差 $\|r_p\|_2 \leq 10^{-6}$ 且平稳性残差 $\|r_s\|_2 \leq 10^{-6}$, 或最大外层迭代 500 步;
- 乘子更新规则: $\lambda_{k+1} = \lambda_k + c(Ax_{k+1} - b)$;
- 每组参数设置重复 3 次随机实验, 取平均值作为统计结果。

4.3 残差术语规范

统一采用 ALM 标准残差定义, 不使用 ADMM 语境下的“对偶残差”表述:

1. 原始残差 (primal residual): $r_p^k = Ax_k - b$, 衡量约束违反程度;
2. 平稳性残差 (stationarity residual): $r_s^k = \nabla f(x_k) + A^\top \lambda_k$, 衡量一阶平稳性条件满足程度。

5 核心实验设计

5.1 实验 1: 基础 c -敏感性分析

实验定位: 基础基准实验, 回答 RQ1 的外层收敛规律。

固定条件: 基准问题 $\kappa(H) = 100$, 内层精度设置两组对照 (精确组 $\epsilon_{\text{inner}} = 10^{-12}$ 、典型不精确组 $\epsilon_{\text{inner}} = 10^{-4}$)。

扫描变量: 惩罚参数 $c \in \{10^{-4}, 10^{-3}, \dots, 10^4\}$ 。

核心观测指标:

- 逐轮原始残差 $r_p(k)$ 演化;

- 逐轮平稳性残差 $r_s(k)$ 演化;
- 收敛所需外层迭代次数 N_{outer} 。

实验内容与分析要点:

1. 分别在精确 ALM 与不精确 ALM 两种场景下, 遍历所有 c 值运行算法, 记录完整收敛轨迹;
2. 绘制不同 c 下的残差收敛曲线 (对数坐标), 对比外层收敛速率随 c 的变化趋势;
3. 对比精确与不精确场景的差异: 验证精确场景下收敛速度随 c 单调提升, 无结构性震荡; 不精确场景下大 c 区域出现收敛平台与波动;
4. 验证假设 H1 与 H3 的外层收敛部分。

5.2 实验 2: 计算成本权衡与最优 c

实验定位: 效率分析实验, 回答 RQ2 的计算权衡问题。

固定条件: 基准问题 $\kappa(H) = 100$, 典型不精确场景 $\epsilon_{\text{inner}} = 10^{-4}$ 。

扫描变量: 惩罚参数 c 全网格。

核心观测指标:

- 单轮平均内层迭代数 N_{inner} ;
- 收敛所需外层迭代数 N_{outer} ;
- 全程累计总内层迭代数 $N_{\text{inner,total}}$;
- 总 CPU 运行时间。

实验内容与分析要点:

1. 统计每个 c 对应的外层迭代开销、内层单轮开销、总计算开销;
2. 绘制“总内层迭代数 vs c ”与“CPU 时间 vs c ”曲线, 验证是否呈现先降后升的 U 型分布;
3. 定位计算意义上的最优惩罚参数 $c_{\text{computational}}^*$, 即总计算代价最小的 c 取值;
4. 分解 U 型曲线的成因: 左侧由外层收敛过慢主导, 右侧由内层条件数恶化主导, 验证假设 H2。

5.3 实验 3: 条件数 $\times$ 内层精度的耦合影响

实验定位: 核心创新实验, 回答 RQ3 的最优参数依赖性问题。

改变变量: 原问题条件数 $\kappa(H) \in \{10^1, 10^2, 10^3, 10^4\}$ 、内层求解精度 $\epsilon_{\text{inner}} \in \{10^{-2}, 10^{-4}, 10^{-6}\}$; 额外纳入 $\epsilon_{\text{inner}} = 10^{-12}$ 作为 high-accuracy reference, 用于近似精确 ALM。

扫描变量: 每组参数组合下遍历全量 c 。

核心问题: 最优惩罚参数是否同时依赖于问题条件数与内层精度, 即 $c^* = c^*(\kappa(H), \epsilon_{\text{inner}})$?

实验内容与分析要点:

1. 对 4×3 组参数组合, 分别重复实验 2 的完整流程, 计算每组对应的最优 c^* ;
2. 固定内层精度, 对比不同条件数下 c^* 的变化: 验证原问题越病态, 最优 c^* 越小 (假设 H5);
3. 固定问题条件数, 对比不同内层精度下 c^* 的变化: 验证内层精度越松, 最优 c^* 越小 (假设 H4);

4. 绘制二维热力图或多组对比曲线，例如横轴 $\log_{10} \kappa$ 、纵轴 $\log_{10} \epsilon_{\text{inner}}$ 、颜色 $\log_{10} c^*$ ，系统展示 c^* 随两个因素的漂移规律；如果有规律，尝试拟合

$$\log c^* = a + b \log \kappa + d \log \epsilon_{\text{inner}},$$

如果拟合不出线性关系，则说明 c^* 不满足简单幂律关系。

5.4 实验 4：固定 c vs 自适应 c

实验定位：延伸应用实验，作为前三部分结论的自然落地。

对比对象：

- 对照组：实验 2 中得到的最优固定 $c_0 = c_{\text{computational}}^*$ ；
- 实验组：两种经典自适应 c 策略
 1. 固定倍率递增：每 5 轮外层迭代，令 $c_{k+1} = 1.5 \cdot c_k$ ；
 2. 残差平衡自适应：若原始残差 > 10 倍平稳性残差，则增大 c ，否则保持不变；增大方式为倍增 $c_{k+1} = \gamma c_k$ (γ 取 2 或 5)，同时设置 c 的最大值和最小值。

核心问题：自适应调整策略能否在无需预调参的前提下，逼近最优固定 c 的计算效率？

实验内容与分析要点：

1. 在基准问题与多组条件数问题上，分别运行固定最优 c 与自适应策略；
2. 对比总计算效率、收敛平稳性、最终精度三个维度的表现；
3. 验证自适应策略的价值：在问题特性未知时，能否自动找到接近最优的惩罚强度，避免手动调参成本。

6 观测指标体系汇总

本章汇总实验所需观测指标，分为收敛轨迹类、计算效率类和数值条件类三类。

6.1 收敛轨迹类（逐轮记录）

- 原始残差 $\|r_p^k\|_2$ ；
- 目标函数相对误差 $|f(x_k) - f^*|/|f^*|$ ；
- 平稳性残差 $\|r_s^k\|_2$ ；
- 乘子相对误差 $\|\lambda_k - \lambda^*\|_2 / \|\lambda^*\|_2$ 。

6.2 计算效率类（聚合统计）

- 收敛所需外层迭代次数；
- 单轮平均内层迭代次数；
- 全程累计总内层迭代次数；
- 总 CPU 运行时间。

6.3 数值条件类

- 子问题海森矩阵条件数 $\kappa(H_c)$;
- 子问题最大/最小特征值;
- 内层迭代步数与条件数的相关系数。

7 结果判定标准

各研究假设的成立判定以实验数据为准，具体判定规则明确如下：

1. **H1 成立判定：**随 c 增大，达到相同原始残差精度所需的外层迭代数总体下降，即外层收敛速率总体提升；同时单轮平均内层迭代数总体上升。两个趋势同时出现时，认为 H1 成立，即 c 在外层收敛速度与内层求解成本之间形成权衡关系。
2. **H2 成立判定：**在不精确 ALM 场景下，考察总计算代价（总内层迭代数或 CPU 时间）随 c 的变化曲线。若曲线存在内部最小值，则表现为 U 型，H2 成立；若最优 c 落在扫描边界，则报告为边界最优，并明确标注该边界情形。
3. **H3 成立判定：**在精确 ALM 场景下，外层收敛速度随 c 增大单调提升（或达到相同残差精度所需的外层迭代数单调不增），且无显著震荡与收敛平台；同时，震荡与收敛平台仅在不精确 ALM 的大 c 区域出现。若精确场景出现明显震荡或平台，则 H3 不成立。
4. **H4 成立判定：**固定问题条件数，随着内层求解精度变松（ ϵ_{inner} 增大），最优惩罚参数 c^* 总体向更小方向漂移；若 c^* 随 ϵ_{inner} 出现系统性漂移且方向与假设一致，则 H4 成立。
5. **H5 成立判定：**固定内层精度，随着原问题条件数 $\kappa(H)$ 增大（问题更病态），最优惩罚参数 c^* 总体向更小方向漂移，且大 c 区域的内层条件恶化效应（如单轮内层迭代数、子问题条件数）增强更显著；若满足上述规律，则 H5 成立。

8 实验结果与分析

本章基于批量实验结果，依次回答三个核心研究问题，并对研究假设 H1–H5 的成立情况进行检验。所有统计均基于达到外层终止条件的收敛试验，最优惩罚参数 c^* 定义为在收敛试验中平均总内层迭代次数最小的 c 。

8.1 实验 1：外层收敛行为与 RQ1

图 8-1 给出了 $\kappa(H) = 100$ 下不同惩罚参数 c 的原始残差收敛轨迹，分别对应典型不精确内层求解（ $\epsilon_{\text{inner}} = 10^{-4}$ ）与精确内层求解（ $\epsilon_{\text{inner}} = 10^{-12}$ ）。




图 8-1: 实验 1: 不同惩罚参数 c 下 ALM 原始残差收敛轨迹

可以看出:

- 在可收敛的 c 范围内, c 越大, 原始残差下降越快, 外层所需迭代数越少, 说明增大 c 总体提升外层收敛速率;
- 精确内层求解 (右图) 下, 各 c 的收敛轨迹平滑, 未出现结构性震荡;
- 不精确内层求解 (左图) 下, 过小的 c 收敛缓慢; 较大的 c 原始残差下降更快。需要说明的是, 图 8-1 仅展示原始残差轨迹, 平稳性残差是否达到终止容差需结合批量统计判断: 部分大 c 组合的平稳性残差未能同步达到 10^{-6} , 表现为不精确 ALM 的数值平台。

从图 8-1 还可看到, 左右两图的原始残差轨迹形态接近, 说明内层精度对原始残差下降轨迹的影响有限; 二者的差异主要体现在平稳性残差是否达到终止容差。因此, RQ1 的回答为: 惩罚参数 c 主要通过约束惩罚强度影响外层收敛速率; c 越大, 原始残差收敛越快, 但该结论依赖于内层求解精度。在精确 ALM 下, c 的作用主要体现在收敛速率; 在不精确 ALM 下, 过大的 c 会因内层误差放大而产生收敛平台 (需结合平稳性残差统计判断)。

8.2 实验 2: 计算效率权衡与 RQ2

图 8-2 给出 $\kappa(H) = 100, \epsilon_{\text{inner}} = 10^{-4}$ 下平均总内层迭代次数随 c 的变化。




图 8-2: 实验 2: 总内层迭代次数随惩罚参数 c 的变化, 呈现 U 型曲线

结果显示:

- 总内层迭代次数随 c 先降后升, 呈明显 U 型;
- 计算最优惩罚参数约为 $c^* = 10$, 此时平均总内层迭代次数约 266;
- 左侧 (小 c) 成本高由外层收敛过慢主导, 右侧 (大 c) 成本上升由子问题条件数恶化、单轮内层迭代增加主导。

因此, RQ2 的回答为: c 对整体计算效率存在非单调影响, 计算意义上存在最优惩罚参数 c^* , 其取值由外层迭代数与内层求解成本的权衡决定。

8.3 实验 3: 最优惩罚参数的依赖规律与 RQ3

图 8-3 和图 8-4 分别给出固定条件数下不同内层精度的 U 型曲线, 以及固定内层精度下不同条件数的 U 型曲线。




图 8-3: 实验 3: 固定 $\kappa(H) = 100$, 不同内层精度下的 U 型曲线对比图 8-4: 实验 3: 固定 $\epsilon_{\text{inner}} = 10^{-4}$, 不同条件数下的 U 型曲线对比

图 8-5 给出 c^* 随 $\kappa(H)$ 与 ϵ_{inner} 漂移的二维热力图。

图 8-5: 实验 3: c^* 随 $\kappa(H)$ 与 ϵ_{inner} 的漂移热力图

从图中可以观察到:

- 固定 $\kappa(H)$ 时, c^* 随 ϵ_{inner} 增大而明显减小。例如 $\kappa(H) = 100$ 时, $\epsilon_{\text{inner}} = 10^{-12}, 10^{-6}, 10^{-4}, 10^{-2}$ 对应的 c^* 分别约为 1000, 100, 10, 1, 支持假设 H4;
- 固定 ϵ_{inner} 时, c^* 随 $\kappa(H)$ 的变化较弱, 且方向为略微增大而非减小。例如 $\epsilon_{\text{inner}} = 10^{-2}$ 时, $\kappa(H) = 10, 100$ 对应 $c^* = 1$, 而 $\kappa(H) = 1000, 10000$ 对应 $c^* = 10$ 。这与假设 H5 的预期方向相反, 因此 H5 未得到支持;
- 对 4×3 组参数进行幂律拟合得到

$$\log_{10} c^* = -0.83 + 0.23 \log_{10} \kappa(H) - 0.37 \log_{10} \epsilon_{\text{inner}}, \quad R^2 = 0.851.$$

该结果表明 c^* 对内层精度的依赖明显 (系数 -0.37), 对条件数的依赖较弱且为正 (系数 0.23), 不满足原假设中“越病态 c^* 越小”的简单幂律方向。

为了解释 H5 未支持的原因, 图 8-6 给出了子问题条件数 $\kappa(H_c)$ 随惩罚参数 c 的变化, 并标注了各参数组合的计算最优 c^* 。




图 8-6: 子问题条件数 $\kappa(H_c)$ 随 c 的变化及计算最优 c^* 位置

可以看出, $\kappa(H_c)$ 并非仅由 $\kappa(H)$ 决定, 而是同时取决于 c 、 $A^\top A$ 以及二者谱结构的相互作用。例如, 在 $\epsilon_{\text{inner}} = 10^{-2}$ 时, $\kappa(H) = 10, 100, 1000, 10000$ 对应的最优 c^* 处 $\kappa(H_{c^*})$ 分别约为 $1.7 \times 10^2, 1.7 \times 10^2, 1.4 \times 10^3, 5.3 \times 10^3$, 并未随 $\kappa(H)$ 等比例恶化。此外, 图 8-6 还显示, 当 c 较大时, 不同 $\kappa(H)$ 对应的 $\kappa(H_c)$ 曲线会发生交叉, 原始条件数较小的问题在大 c 下反而可能具有更大的子问题条件数, 进一步说明 $\kappa(H)$ 不能单独预测子问题求解难度。这表明 H5 的原始推理“ $\kappa(H)$ 越大, 大 c 越不划算”过于简化; 真正决定内层求解难度的量是增广后子问题的条件数 $\kappa(H_c)$, 而不是原问题条件数 $\kappa(H)$ 。

因此, RQ3 的回答为: 最优惩罚参数 c^* 确实依赖于内层求解精度与问题条件数, 即 $c^* = c^*(\kappa(H), \epsilon_{\text{inner}})$; 其中对 ϵ_{inner} 的依赖显著且方向稳定, 对 $\kappa(H)$ 的依赖较弱, 且实验方向与初始假设 H5 相反。

8.4 内层迭代成本与子问题条件数的关系

图 8-7 给出平均单轮内层迭代次数与子问题条件数 $\kappa(H_c)$ 的双对数散点图, 并按内层精度分组拟合。




图 8-7: 内层迭代步数与子问题条件数的相关性（按内层精度分组拟合）

结果显示：

- 在双对数坐标下，各组数据近似呈线性上升，支持内层迭代步数与 $\kappa(H_c)$ 之间存在幂律关系；
- 四组拟合斜率均在 0.13 ~ 0.15 之间，说明内层迭代步数对条件数的依赖较弱，与 CG 理论中 $\sqrt{\kappa}$ 的粗略上界相比，实际依赖更温和；
- 内层精度越高（ ϵ_{inner} 越小），相同条件数下的迭代步数越多，曲线整体上移。

8.5 研究假设检验总结

综合上述结果，各研究假设的检验结论如下：

- **H1（支持）**： c 增大总体提升外层收敛速率，同时增大单轮内层求解成本，二者形成权衡关系；
- **H2（支持）**：不精确 ALM 场景下总计算代价随 c 呈 U 型，存在内部最优 c^* ；
- **H3（部分支持）**：精确 ALM 场景下收敛平稳、无显著震荡；不精确 ALM 场景下大 c 区域出现收敛平台/平稳性残差难以进一步下降。但“震荡”现象在本实验参数范围内并不普遍，因此只能说部分支持；
- **H4（支持）**：内层精度越松，最优 c^* 越小；
- **H5（不支持，需修正）**：最优 c^* 随 $\kappa(H)$ 增大并未如预期减小，反而略有增大。更准确的认识是： c^* 不由 $\kappa(H)$ 单独决定，而由增广子问题条件数 $\kappa(H_c)$ 与外层收敛收益共同决定； $\kappa(H)$ 本身不是充分的参数选择指标。

9 理论机制分析

本节将实验结果与 ALM/CG 的理论性质联系起来，给出惩罚参数 c 影响总计算代价的完整数学链条，并解释 H4、H5 的深层原因。

9.1 外层加速：乘子误差传播

考虑精确 ALM 情形。设 $M_c = H + cA^\top A$ ，子问题精确解为 $x_{k+1} = M_c^{-1}(q - A^\top \lambda_k + cA^\top b)$ 。由 KKT 条件，最优乘子满足 $q = Hx^* + A^\top \lambda^*$ 和 $Ax^* = b$ 。记乘子误差 $e_{\lambda,k} = \lambda_k - \lambda^*$ ，经整理可得

$$e_{\lambda,k+1} = (I + cS)^{-1}e_{\lambda,k}, \quad S = AH^{-1}A^\top \succ 0. \quad (8)$$

设 S 的特征值为 $\mu_i > 0$ ，则对应方向的收缩因子为

$$\rho_i(c) = \frac{1}{1 + c\mu_i}. \quad (9)$$

因此 c 越大， $\rho_i(c)$ 越小，外层乘子误差收敛越快。这解释了实验 1 中“ c 增大使原始残差下降更快”的现象。

9.2 内层代价：CG 与子问题谱

内层用 CG 求解 $M_c x = rhs$ 。经典 CG 误差界给出达到精度 ϵ_{inner} 所需迭代步数约为

$$N_{\text{CG}} \sim O\left(\sqrt{\kappa(M_c)} \log \frac{1}{\epsilon_{\text{inner}}}\right). \quad (10)$$

因此 c 通过改变 $M_c = H + cA^\top A$ 的谱结构影响单轮内层成本。值得注意的是，由于 $A^\top A \succeq 0$ ， $\lambda_{\max}(M_c)$ 与 $\lambda_{\min}(M_c)$ 都随 c 单调不减，但 $\kappa(M_c)$ 是否上升取决于二者增长速率的相对大小；在本实验的大 c 区域， $\kappa(M_c)$ 整体上升，导致 CG 成本增加。

9.3 不精确 ALM 的平稳性误差地板

若 CG 未精确求解，则存在内层残差 δ_k 使得

$$M_c x_{k+1} = q - A^\top \lambda_k + cA^\top b + \delta_k. \quad (11)$$

将乘子更新代入平稳性残差 $s_{k+1} = Hx_{k+1} - q + A^\top \lambda_{k+1}$ ，可得

$$s_{k+1} = \delta_k. \quad (12)$$

因此 $\|s_{k+1}\| = \|\delta_k\|$ 。当 CG 采用相对残差终止 $\|\delta_k\| \leq \epsilon_{\text{inner}} \|rhs_k\|$ 时，

$$\|s_{k+1}\| \lesssim \epsilon_{\text{inner}} \|rhs_k\|. \quad (13)$$

这意味着固定内层精度直接形成外层平稳性残差的误差地板：若 $\epsilon_{\text{inner}} = 10^{-4}$ 而外层要求 $\|s_k\| \leq 10^{-6}$ ，则无法保证达标。这从数学上解释了“除精确 ALM 外大量参数不满足终止条件”的初始现象^[3]。

此外，不精确误差还会通过乘子更新进入外层迭代。设 $x_{k+1} = x_{k+1}^{\text{exact}} + e_k$ ， $e_k = M_c^{-1}\delta_k$ ，则乘子更新中的扰动为 $cAM_c^{-1}\delta_k$ 。于是不精确 ALM 的乘子误差传播为

$$e_{\lambda,k+1} = (I + cS)^{-1}e_{\lambda,k} + cAM_c^{-1}\delta_k. \quad (14)$$

前一项随 c 增大而收缩（有利），后一项随 c 增大而放大内层误差（不利）。这解释了大 c 下不精确 ALM 更容易出现收敛平台的现象。

9.4 总成本与 c^* 的决定

综合上述机制，总计算代价可近似表示为

$$C(c, \epsilon_{\text{inner}}) \approx N_{\text{outer}}(c, \epsilon_{\text{inner}}) \cdot N_{\text{CG}}(c, \epsilon_{\text{inner}}), \quad (15)$$

其中 N_{outer} 随 c 增大而下降（来自收缩因子 $\rho(c)$ ）， N_{CG} 随 c 增大而上升（来自 $\kappa(M_c)$ 增大），二者竞争产生 U 型曲线与内部最优 c^* 。

进一步，当 ϵ_{inner} 减小时， N_{CG} 整体增大，减少一次外层迭代的边际收益变高，因此最优 c^* 向右移动。这解释了 H4。

9.5 H5 的深层原因：谱方向相互作用

H5 的原始假设 $\kappa(H) \uparrow \Rightarrow c^* \downarrow$ 隐含了“ $\kappa(H)$ 能决定子问题难度”的假设。但外层收敛真正涉及 $S = AH^{-1}A^\top$ ，内层真正涉及 $H + cA^\top A$ ，二者都依赖于 H 的特征向量方向与 A 的约束方向之间的相对位置。设 $H = Q\Lambda Q^\top$ ，则

$$AH^{-1}A^\top = A Q \Lambda^{-1} Q^\top A^\top, \quad (16)$$

其中 AQ 明确刻画了这一相对位置；同理， $H + cA^\top A$ 的特征值并不是简单的 $\lambda_i(H) + c\lambda_i(A^\top A)$ ，除非 H 与 $A^\top A$ 可同时对角化。因此，仅控制 $\kappa(H)$ 无法确定 $\kappa(H_c)$ 与外层收敛收益，H5 的因果链条少了一层。修正后的认识是：

c^* 由 $\kappa(H_c)$ （受 $H, A^\top A, c$ 谱结构共同决定）与外层收敛收益（受 $AH^{-1}A^\top$ 决定）共同决定。

这也解释了实验中不同 $\kappa(H)$ 的 $\kappa(H_c)$ 曲线发生交叉的现象。

10 讨论与结论

本文围绕增广拉格朗日方法中的惩罚参数 c ，通过“KKT reference + ALM + CG”的可复现实验体系，系统研究了 c 对外层收敛行为、整体计算效率以及最优参数选择的影响。主要发现如下：

1. **外层收敛与内层成本存在 U 型权衡：** c 增大加快原始残差收敛，但同时提高子问题条件数 $\kappa(H_c)$ 与单轮内层求解成本，因此总计算代价随 c 呈 U 型，存在计算最优 c^* 。
2. **内层精度改变成本权衡的相对重要性：** ϵ_{inner} 越严，单次内层求解越昂贵，减少外层迭代的边际收益越大，导致 c^* 向较大区域移动。这为 H4 提供了机制层面的解释，而不仅是现象描述。
3. **$\kappa(H)$ 不是预测 c^* 的充分指标：** 实验表明 c^* 随 $\kappa(H)$ 增大略微增大，与 H5 的初始预期相反。进一步分析显示，真正决定内层求解难度的量是增广子问题条件数 $\kappa(H_c)$ ，而 $\kappa(H_c)$ 同时受 c 、 $A^\top A$ 以及二者谱结构相互作用的影响。因此，H5 应修正为： c^* 由增广后子问题的谱性质与外层收敛收益共同决定。

本文的结论可以概括为：惩罚参数 c 并不是一个可以脱离问题结构而固定的 ALM 常数；其最优取值依赖于内层求解精度以及增广后子问题的实际数值条件。这一认识对于实际使用 ALM 时进行参数自适应具有直接指导意义。

本研究的局限性包括：参数网格较粗（ c 按数量级扫描）， c^* 的精确位置可能位于网格之间；实验仅覆盖对称正定二次规划基准问题；自适应 c 策略（实验 4）尚未纳入本文结果。后续工作可以在 c^* 附近加密网格，并进一步验证自适应策略在问题特性未知时的表现。

参考文献

- [1] D. P. Bertsekas. *Constrained Optimization and Lagrange Multiplier Methods*. Academic Press, 1982.
- [2] M. R. Hestenes and E. Stiefel. Methods of conjugate gradients for solving linear systems. *Journal of Research of the National Bureau of Standards*, 49(6):409–436, 1952.

- [3] D. Fernández and M. V. Solodov. Local convergence of exact and inexact augmented Lagrangian methods under the second-order sufficient optimality condition. *SIAM Journal on Optimization*, 22(2):384–407, 2012.